

西安交通大學
XI'AN JIAOTONG UNIVERSITY

《优化方法基础》

2025-2026学年春季学期

罗敏楠
计算机科学与技术学院
西安交通大学

课程基本信息

教师：罗敏楠（西一楼440房间）

Email：minnluo@xjtu.edu.cn

考试成绩

50%平时作业+50%大作业

参考书目

[1] Boyd, Stephen and Lieven Vandenberghe. Convex optimization. Cambridge University Press, 2009. (https://web.stanford.edu/~boyd/cvxbook/bv_cvxbook.pdf

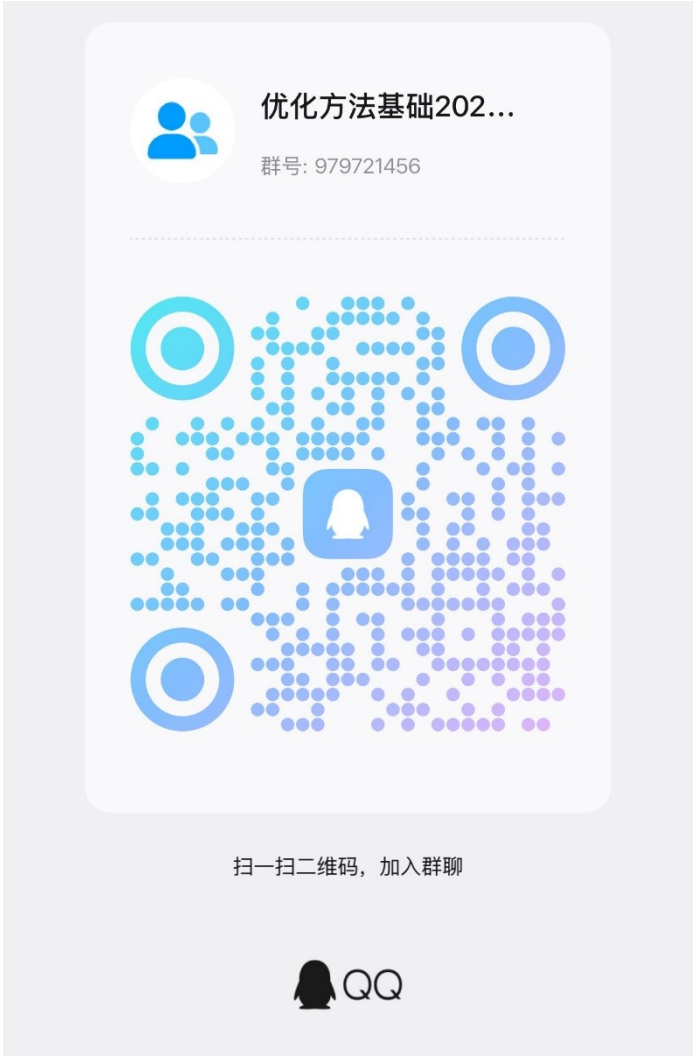
[2]王书宁等翻译版本，《凸优化》，清华大学出版社

http://web.stanford.edu/~boyd/cvxbook/



学习目标

基本概念、基本原理、基本方法


优化方法基础202...
群号: 979721456
扫一扫二维码，加入群聊
QQ

优化的重要意义

- 最优化是工程技术、经济管理、科学研究中经常遇到的问题。例如：
  - ✓结构设计
  - ✓资源分配
  - ✓生产计划
  - ✓运输方案
  - ✓模式识别、数据挖掘、机器学习
  - ✓深度学习、强化学习、人工智能

CMU《Convex Optimization》
https://scs.hosted.panopto.com/Panopto/Pages/Sessions/List.aspx#folderID=%222e05ff30-48ba-4598-9f70-a9430132b706%22

- 解决优化问题的手段

经验积累 主观判断	做实验 比优劣	建立数学模型 求解最优策略



Optimization problems underlie nearly everything we do in Machine Learning and Statistics. In many courses, you learn how to:

translate  into $P: \min_{x \in D} f(x)$

Conceptual idea *Optimization problem*

Examples of this? Examples of the contrary?

This course: how to solve P, and why this is a good skill to have

例子

投资组合优化

- 变量x_i：第i项投资财产的数目，$i = 1,2,\cdots,n$。
- 限制条件$f_i(x_i)$，$h_j(x_j)$：各项财产最大/最小投资额、最小收益等限制条件
- 目标$f_0(x) = \sum_{i=1}^{n} f_0(x_i)$：总投资风险最小(或者总收益最大)

$$\begin{aligned} \min_{x} \quad & f_0(x) = \sum_{i=1}^{n} f_0(x_i) \\ s.t. \quad & f_i(x_i) \le 0 \ (i = 1,2,\cdots,p) \\ & h_j(x_j) = 0, \ (j = 1,2,\cdots,q) \end{aligned}$$

优化问题数学标准形式

优化变量 x

$$\min_{x} \quad f_0(x) \longrightarrow \text{目标函数}$$

$$s.t. \quad f_i(x) \le 0 \ (i = 1,2,\cdots,m) \longrightarrow \text{不等式限制}$$

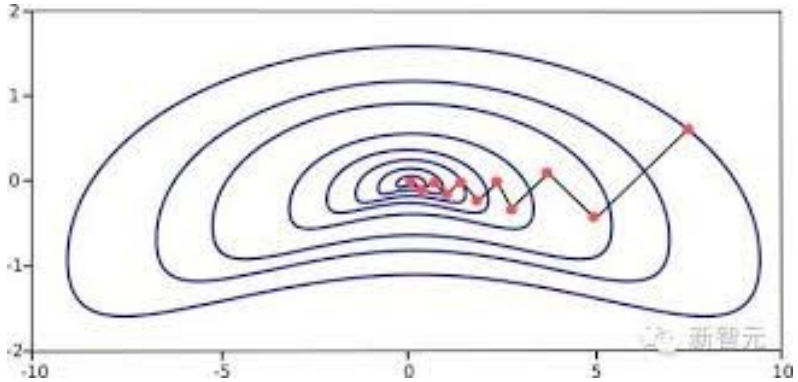
$$h_j(x) = 0, \ (j = 1,2,\cdots,n) \longrightarrow \text{等式限制}$$

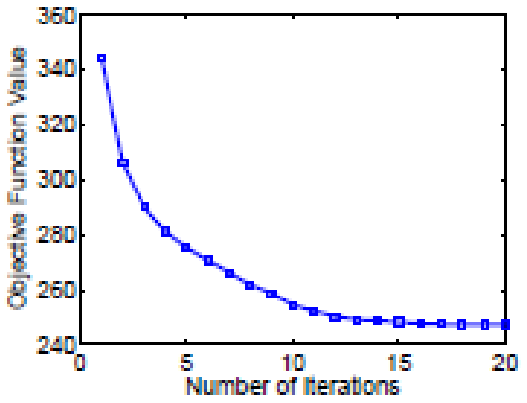
- 可行解集$X = \{x \in \mathbb{R}^n : f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$
- 最优值 $p^* = \inf\{f_0(x) : x \in X\}$
- 最优解$x^* \in X : f_0(x^*) = p^*$
- 最优解不唯一
- 局部极小解：$\exists \epsilon > 0$，使得$\forall x \in X, \|x - \hat{x}\|_2 < \epsilon$，有$f(\hat{x}) \le f(x)$, 称$\hat{x}$为$f$的局部极小解
- 全局最小解：如果$\forall x \in X$，有$f(\hat{x}) \le f(x)$成立，称$\hat{x}$为f的全局最小解。

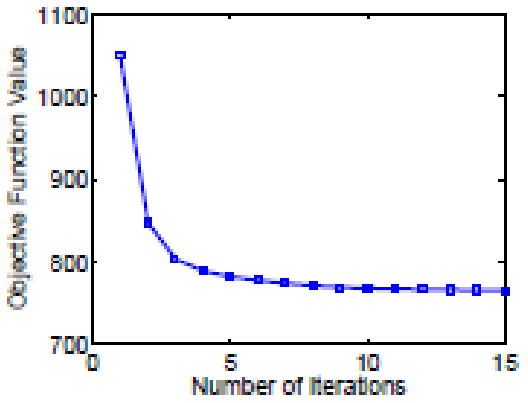
求解优化问题

$$\begin{aligned} \min_{x} \quad & f_0(x) \\ s.t. \quad & f_i(x) \le 0 \ (i = 1,2,\cdots,m) \\ & h_j(x) = 0, \ (j = 1,2,\cdots,n) \end{aligned}$$

- 一般优化问题
  - 难于求解
  - 计算复杂度高、需要时间长、不总能找到最优解
- 特定的优化问题能够有效、可靠的求解，例如
  - 线性规划问题
  - 二次规划问题（最小二乘问题）
  - 图优化问题
  - 凸优化问题







线性规划问题（Linear Programming）

- 目标函数和限制函数都为线性函数，即

$$\begin{aligned} \min \quad & c_1x_1 + c_2x_2 + \cdots + c_nx_n \\ s.t. \quad & a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \leq b_i \ (i = 1,2,\cdots,m) \end{aligned}$$

- 矩阵形式：

$$\begin{aligned} \min \quad & c^{\mathsf{T}}x \\ s.t. \quad & Ax \leq b \end{aligned}$$

这里，$c = (c_1, c_2, \cdots, c_n)^{\mathsf{T}}, x = (x_1, x_2, \cdots, x_n)^{\mathsf{T}} \in \mathbb{R}^n, A \in \mathbb{R}^{m\times n}, b \in \mathbb{R}^m$.

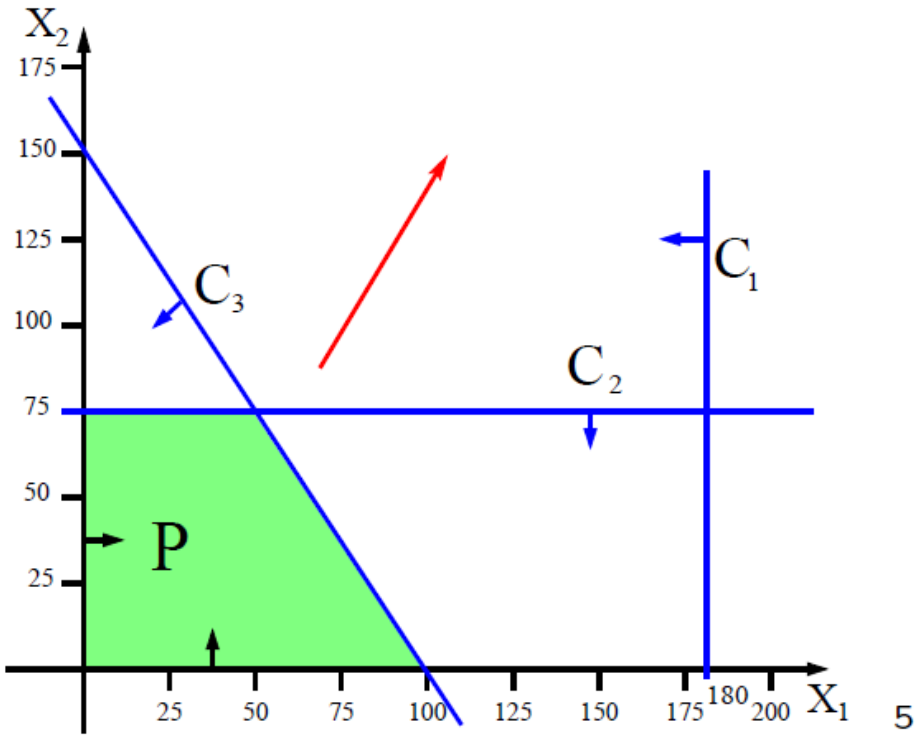
线性规划问题（Linear Programming）

例1、某公司生产产品P1 x_1件，生产产品P2 x_2件，利润最大化函数为

$$\max z = 3x_1 + 5x_2$$

限制条件为

$$\begin{aligned} x_1 &\le 180 \\ 2x_2 &\le 150 \\ 3x_1 + 2x_2 &\le 300 \\ x_1 &\ge 0 \\ x_2 &\ge 0 \end{aligned}$$



线性规划问题（Linear Programming）

$$\begin{aligned} \min_{x} \quad & c^{\top}x \\ s.t. \quad & Ax \leq b \end{aligned}$$

$$c, x \in \mathbb{R}^n, A \in \mathbb{R}^{m\times n}, b \in \mathbb{R}^m$$

- 求解线性规划

- 无分析解（闭式解）
- 有效的算法及成熟的软件
- 计算时间复杂度：如果$m \leq n$，则 $O(n^2 m)$，这里$x \in \mathbb{R}^n$.

二次规划问题（Quadratic Programming）

$$\begin{aligned} \min_{x} \quad & \frac{1}{2}x^{\top}Qx + c^{\top}x + d \\ s.t. \quad & Ax = b \end{aligned}$$

这里，$Q = (q_{ij}) \in \mathbb{R}^{n\times n}$为对称矩阵,矩阵$A \in \mathbb{R}^{m\times n}, c, x \in \mathbb{R}^{n}, b \in \mathbb{R}^{m}, c \in \mathbb{R}.$

非线性优化问题(Nonlinear Optimization)

$$\min_{x} \quad f_0(x)$$

$$s.t. \quad f_i(x) \leq 0 \ (i = 1,2,\cdots,m)$$

$$h_j(x) = 0, \ (j = 1,2,\cdots,n)$$

至少有一项是
非线性函数

非线性优化问题(Nonlinear Optimization)

$$\begin{aligned} \min \quad & (x_1-x_2)^2+(y_1-y_2)^2+(z_1-z_2)^2 \\ \text{s.t.} \quad & x_1^2+y_1^2+z_1^2=1, \\ & \frac{(x_2-p)^2}{a^2}+\frac{(y_2-q)^2}{b^2}+\frac{(z_2-r)^2}{c^2}=1. \end{aligned}$$

- 举例：球面$S=\{(x,y,z)\in\mathbb{R}^3: x^2+y^2+z^2=1\}, (x_1,y_1,z_1)\in S,$

$$\text{椭球面} E=\left\{(x,y,z)\in\mathbb{R}^3: \frac{(x-p)^2}{a^2}+\frac{(y-q)^2}{b^2}+\frac{(z-r)^2}{c^2}=1\right\}, (x_2,y_2,z_2)\in E$$

从球面到椭球面的距离：

$$d(S,E)=\min\{d((x_1,y_1,z_1),(x_2,y_2,z_2))\}$$

最小二乘问题(Least Square Problem)

$$\min \|Ax - b\|_2^2$$

求解最小二乘问题

- 分析解（闭式解）：$x^* = (A^\top A)^{-1} A^\top b$
- 有效的算法及成熟的软件
- 计算时间复杂度$O(n^2 m)$，$A \in \mathbb{R}^{m \times n}$。

使用最小二乘

- 一些标准的技术提高其适应性。例如，增加权重、增加调整项等。

凸优化问题

$$\begin{aligned} \min_{x} \quad & f_0(x) \\ s.t. \quad & f_i(x) \le 0 \ (i = 1,2,\cdots,m) \\ & h_j(x) = 0, \ (j = 1,2,\cdots,n) \end{aligned}$$

1. 什么是**凸优化问题**？

答：目标函数f_0和不等式限制函数$f_i(i = 1,2,\cdots,m)$都是定义在**凸集**上的**凸函数，** $h_j(x)$ $(j = 1,2,\cdots,n)$为仿射函数。

2. 什么是**凸集**？
3. 什么是**凸函数**？
4. ……

□求解凸优化问题

- 无分析解
- 有效、可靠的算法

□使用凸优化

- 通过一些技巧，许多问题可以转化为凸优化问题
- 凸优化问题有一套理论较为完善的求解方法。

有关的数学知识

- 范数
- 导数
- 线性代数
- 求解不确定线性方程组$Ax = b$

内积和范数

- n维实向量集合$\mathbb{R}^n$上的标准内积：$\forall x = (x_1, x_2, \cdots, x_n)^\top \in \mathbb{R}^n, y = (y_1, y_2 \cdots, y_n)^\top \in \mathbb{R}^n,$

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^{n} x_i y_i$$

- Euclid范数(ℓ_2-范数)： $\forall x = (x_1, x_2, \cdots, x_n)^\top \in \mathbb{R}^n,$

$$\|x\|_2 = (x^\top x)^{1/2} = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}$$

- 两个非零向量$x, y \in \mathbb{R}^n$的夹角：

$$\angle(x, y) = arccos\left(\frac{x^\top y}{\|x\|_2 \|y\|_2} \right) \in [0, \pi]$$

- Cauchy-Schwartz不等式：$\forall x, y \in \mathbb{R}^n, |x^\top y| \leq \|x\|_2 \|y\|_2$

内积和范数

- $n \times n$对称矩阵集合S^n上的标准内积为, $\forall X, Y \in S^n$,

$$\langle X, Y \rangle = tr(X^\top Y) = \sum_{i=1}^{n}\sum_{j=1}^{n} x_{ij}y_{ij} = \sum_{i=1}^{n} x_{ii}y_{ii} + 2\sum_{i<j} x_{ij}y_{ij}$$

- 矩阵$X = [x_{ij}] \in \mathbb{R}^{m\times n}$的Frobenius范数定义为

$$\|X\|_F = \left(tr(X^\top X)\right)^{1/2} = \left(\sum_{i=1}^{m}\sum_{j=1}^{n} x_{ij}^2\right)^{1/2}$$

范数

- 范数定义：满足以下条件的函数$f: \mathbb{R}^n \longmapsto \mathbb{R}, \mathrm{dom} f = \mathbb{R}^n$称为范数
  - ✓ f是非负的：$\forall x \in \mathbb{R}^n$，有$f(x) \geq 0$
  - ✓ f是正定的：若$f(x) = 0$，则$x = 0$
  - ✓ f是齐次的：$\forall x \in \mathbb{R}^n$和$t \in \mathbb{R}$，有$f(tx) = |t| f(x)$
  - ✓ f满足三角不等式：：$\forall x, y \in \mathbb{R}^n$，有$f(x + y) \leq f(x) + f(y)$

- 范数采用符号$f(x) = \|x\|$，范数是对向量$x \in \mathbb{R}^n$的长度的度量。
- 两个向量$x, y \in \mathbb{R}^n$之间用范数$\|\cdot\|$表示的距离定义为：

$$dist(x, y) = \|x - y\|$$

l_p–范数

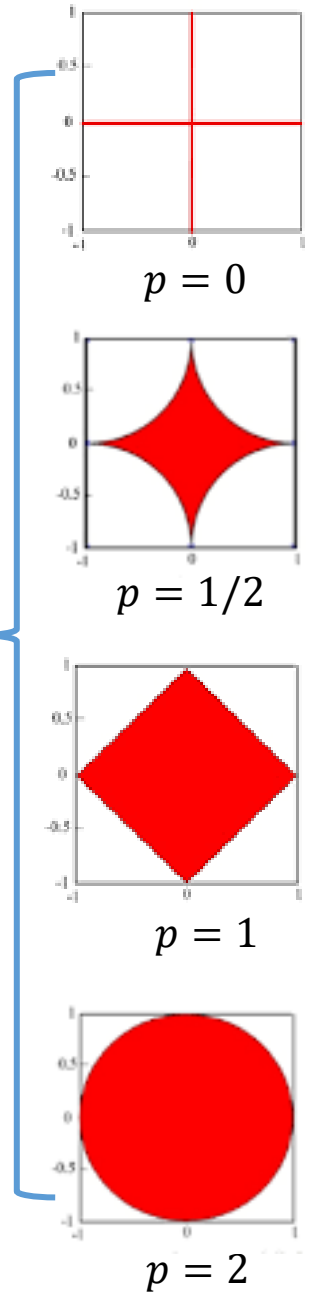
- l_p范数$(p \geq 1)$

$$\|x\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{1/p} = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}$$

  - ✓ l_1 范数: $\|x\|_1 = |x_1| + |x_2| + \cdots + |x_n| = \sum_{i=1}^{n} |x_i|$
  - ✓ l_2 范数(Eucild范数): $\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2\right)^{1/2}$
  - ✓ Chebyshev或l_∞范数: $\|x\|_\infty = max\{|x_1|, |x_2|, \cdots, |x_n|\}$

- “l_0范数” $\|x\|_0$ =向量x中非零元素的个数

$\|x\|_p = 1$



回顾：范数

- 范数定义：满足以下条件的函数$f: \mathbb{R}^n \longmapsto \mathbb{R}, \mathrm{dom} f = \mathbb{R}^n$称为范数
  - ✓ f是非负的：$\forall x \in \mathbb{R}^n$，有$f(x) \geq 0$
  - ✓ f是正定的：若$f(x) = 0$，则$x = 0$
  - ✓ f是齐次的：$\forall x \in \mathbb{R}^n$和$t \in \mathbb{R}$，有$f(tx) = |t| f(x)$
  - ✓ f满足三角不等式：：$\forall x, y \in \mathbb{R}^n$，有$f(x + y) \leq f(x) + f(y)$

- 范数采用符号$f(x) = \|x\|$，范数是对向量$x \in \mathbb{R}^n$的长度的度量。
- 两个向量$x, y \in \mathbb{R}^n$之间用范数$\|\cdot\|$表示的距离定义为：

$$dist(x, y) = \|x - y\|$$

l_p–范数

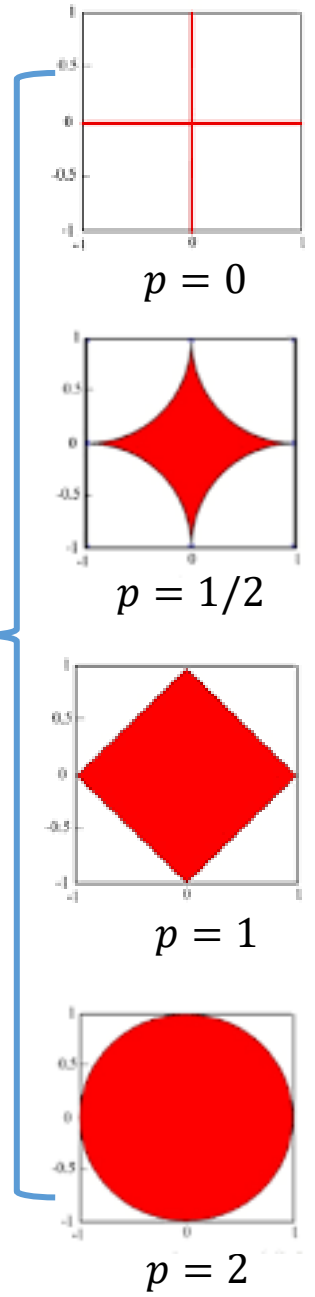
- l_p范数$(p \geq 1)$

$$\|x\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{1/p} = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}$$

  - ✓ l_1 范数: $\|x\|_1 = |x_1| + |x_2| + \cdots + |x_n| = \sum_{i=1}^{n} |x_i|$
  - ✓ l_2 范数(Eucild范数): $\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2\right)^{1/2}$
  - ✓ Chebyshev或l_∞范数: $\|x\|_\infty = max\{|x_1|, |x_2|, \cdots, |x_n|\}$

- “l_0范数” $\|x\|_0$ =向量x中非零元素的个数

$\|x\|_p = 1$



二次范数

- 对$P \in S_{++}^{n}$，定义P −二次范数如下：

$$\|x\|_P = (x^\top P x)^{1/2} = \left\|P^{1/2}x\right\|_2$$

1. 二次范数的单位球是椭圆；
2. 如果一个范数的单位球是椭圆，该范数是二次范数
3. 当$P = I$（单位矩阵）时，P −二次范数退化为l_2 范数(Eucild范数)

矩阵范数

- 矩阵$X = [x_{ij}] \in \mathbb{R}^{m\times n}$的Frobenius范数

$$\|X\|_F = \left(tr(X^{\top}X)\right)^{1/2} = \left(\sum_{i=1}^{m}\sum_{j=1}^{n} x_{ij}^2\right)^{1/2}$$

- 矩阵$X = [x_{ij}] \in \mathbb{R}^{m\times n}$的绝对值之和范数

$$\|X\|_{sav} = \sum_{i=1}^{m}\sum_{j=1}^{n} |x_{ij}|$$

- 矩阵$X = [x_{ij}] \in \mathbb{R}^{m\times n}$的最大绝对值范数

$$\|X\|_{mav} = max\{|x_{ij}| : i = 1,2,\cdots,m; j = 1,2,\cdots,n\}$$

范数的等价性

- 令$\|\cdot\|_a$和$\|\cdot\|_b$是$\mathbb{R}^n$上的范数，则存在正常数α, β对所有的$x \in \mathbb{R}^n$，有

$$\alpha\|x\|_a \leq \|x\|_b \leq \beta\|x\|_a$$

  - ✓ 任何有限维向量空间上的范数都是等价的
  - ✓ 推论：任意范数可由Euclid范数进行界定，即存在常数$\gamma \in (0,1]$, 使得

$$\|x\| \geq \gamma\|x\|_2$$

导数

- 假定：$f: \mathbb{R}^n \to \mathbb{R}^m, x \in int\ dom\ f$。函数$f$在$x$处可微，则存在矩阵$Df(x) \in \mathbb{R}^{m \times n}$满足

$$\lim_{z \in dom\ f, z \neq x, z \to x} \frac{\|f(z) - f(x) - Df(x)(z-x)\|_2}{\|z - x\|_2} = 0$$

  - $Df(x) \in \mathbb{R}^{m \times n}$称为$f$在$x$处的导数（或Jacobian矩阵）
  - 偏导数：$Df(x)_{ij} = \frac{\partial f_i(x)}{\partial x_j}, i = 1,2,\cdots,m; j = 1,2,\cdots,n$

- f在x处以z为变量的一次逼近为：$\bar{f}(z) = f(x) + Df(x)(z-x)$

梯度

- 实函数：$f:\mathbb{R}^n \to \mathbb{R}, x \in int\ dom\ f$的导数为行向量$Df(x) \in \mathbb{R}^{1\times n}$，其转置称为函数的梯度，即

$$\nabla f(x) = Df(x)^{\mathsf{T}} \in \mathbb{R}^n，这里\nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}, i = 1,2,\cdots,n$$

- f在$x \in int\ dom\ f$处以z为变量的一次逼近：$\bar{f}(z) = f(x) + \nabla f(x)^{\mathsf{T}}(z-x)$

- 例子：二次函数$f:\mathbb{R}^n \to \mathbb{R}, f(x) = \frac{1}{2}x^{\mathsf{T}}Px + q^{\mathsf{T}}x + r$,其中$P \in S^n, q \in \mathbb{R}^n, r \in \mathbb{R}$. 它在$x$处的导数为$Df(x) = x^{\mathsf{T}}P + q^{\mathsf{T}}$，梯度为$\nabla f(x) = Px + q$

链式规则

- 假定：$f:\mathbb{R}^n \to \mathbb{R}^m$在$x \in int\ dom\ f$处可微，$g:\mathbb{R}^m \to \mathbb{R}^p$在$f(x) \in int\ dom\ g$处可微. 定义复合函数$h:\mathbb{R}^n \to \mathbb{R}^p$为$h(z) = g\big(f(z)\big)$，则函数$h$在$x$处可微，导数为

$$Dh(x) = Dg\big(f(x)\big)Df(x)$$

- 假设以上$f:\mathbb{R}^n \to \mathbb{R}$，$g:\mathbb{R} \to \mathbb{R}$，则函数$h$在$x$处梯度为：$\nabla h(x) = g'\big(f(x)\big)\nabla f(x)$

- 若$f:\mathbb{R}^n \to \mathbb{R}^m$是可微函数，$A \in \mathbb{R}^{n\times p}, b \in \mathbb{R}^n$, 则函数$h:\mathbb{R}^p \to \mathbb{R}^m, h(x) = f(Ax+b)$的导数为$Dh(x) = Df(Ax+b)A$。当$m = 1$时，其梯度为

$$\nabla h(x) = A^{\mathsf{T}}\nabla f(Ax+b)$$

二阶导数

- 实函数$f: \mathbb{R}^n \to \mathbb{R}$在$x \in int\ dom\ f$的二阶导数（Hessian矩阵）为

$$\nabla^2 f(x)_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, i = 1,2,\cdots,n; j = 1,2,\cdots,n$$

- f在$x \in int\ dom\ f$ 处以z为变量的二次逼近为：

$$\hat{f}(z) = f(x) + \nabla f(x)^{\mathrm{T}}(z - x) + \frac{1}{2}(z - x)^{\mathrm{T}}\nabla^2 f(x)(z - x)$$

- 该二次逼近满足

$$\lim_{z \in dom\ f, z \neq x, z \to x} \frac{\left|f(x) - \hat{f}(z)\right|}{\|z - x\|_2^2} = 0$$

二阶导数链式法则

- 假定$f\colon \mathbb{R}^n \to \mathbb{R}, g\colon \mathbb{R} \to \mathbb{R}$以及复合函数$h(x) = g\big(f(x)\big)$，则

$$\nabla^2 h(x) = g'\big(f(x)\big)\nabla^2 f(x) + g''\big(f(x)\big)\nabla f(x)\nabla f(x)^{\mathsf{T}}$$

- 若$f\colon \mathbb{R}^n \to \mathbb{R}$是可微函数，$A \in \mathbb{R}^{n\times m}, b \in \mathbb{R}^n$, 定义$h(x) = f(Ax + b)$，则

$$\nabla^2 h(x) = A^{\mathsf{T}}\nabla^2 f(Ax + b)A$$

作业

$f:\mathbb{R}^n \to \mathbb{R}$，$f(x) = log\sum_{i=1}^{m} exp\left(a_i^{\top}x + b_i\right)$，其中$a_1, a_2, \cdots, a_m \in \mathbb{R}^n$，$b_1, b_2, \cdots, b_m \in \mathbb{R}$

1、求函数f的梯度$\nabla f(x)$

2、求函数f的二阶导数$\nabla^2 f(x)$

凸优化问题

$$\begin{aligned} \min_{x} \quad & f_0(x) \\ s.t. \quad & f_i(x) \le 0 \ (i = 1,2,\cdots,m) \\ & h_j(x) = 0, \ (j = 1,2,\cdots,n) \end{aligned}$$

1. 什么是**凸优化问题**？

答：目标函数f_0和不等式限制函数$f_i(i = 1,2,\cdots,m)$都是定义在**凸集**上的**凸函数，** $h_j(x)$ $(j = 1,2,\cdots,n)$为仿射函数。

2. 什么是**凸集**？
3. 什么是**凸函数**？
4. ……

□求解凸优化问题

- 无分析解
- 有效、可靠的算法

□使用凸优化

- 通过一些技巧，许多问题可以转化为凸优化问题
- 凸优化问题有一套理论较为完善的求解方法。

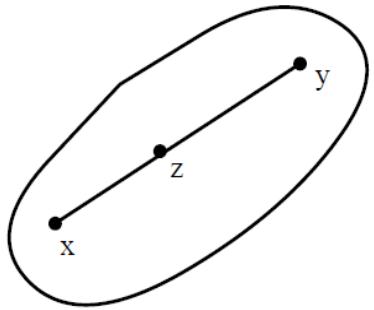
凸集

- 凸集的定义：集合$C \subset \mathbb{R}^n$称为凸集，如果$\forall\, x, y \in C$及$\forall \lambda \in [0,1]$，有

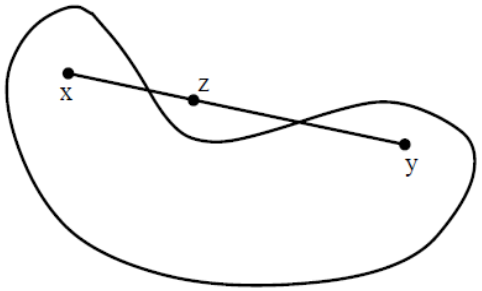
$$z = \lambda x + (1-\lambda) y \in C$$

↓

点x和点y的凸组合



凸集



非凸集

- 凸集中任意两点的连线仍在该集合中

举例

- $\forall n \geq 1$，$\mathbb{R}^n$空间为凸集合；
- 非负象限$\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_i \geq 0, \forall i = 1,2,\cdots,n\}$是凸集合
- 集合$X = \{x \in \mathbb{R}^n : \|x\|_2 \leq 1\}$是凸集

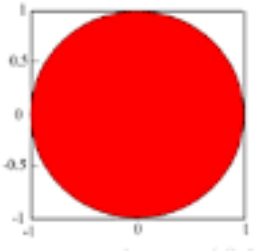
证明：$\forall x, y \in X, \forall \lambda \in [0,1]$,

$$\|\lambda x + (1-\lambda)y\|_2 \leq \|\lambda x\|_2 + \|(1-\lambda)y\|_2$$

范数的三角不等式

$$= \lambda\|x\|_2 + (1-\lambda)\|y\|_2$$

$$\leq 1$$



$p = 2$

凸集的判断

- 根据定义

$$\forall x, y \in C, \forall \lambda \in [0,1] \quad \Longrightarrow \lambda x + (1-\lambda) y \in C$$

- 例子：令$A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^{m}$，集合$C = \{x \in \mathbb{R}^{n} : Ax = b\}$是凸集吗？为什么？

作业

- 令$A \in \mathbb{R}^{m\times n}, B \in \mathbb{R}^{p\times n}, b \in \mathbb{R}^{m}, d \in \mathbb{R}^{p}$，集合

$$P = \{x \in \mathbb{R}^{n} : Ax \leq b \text{ 且} Bx = d\}$$

是凸集吗？为什么？

凸集的性质

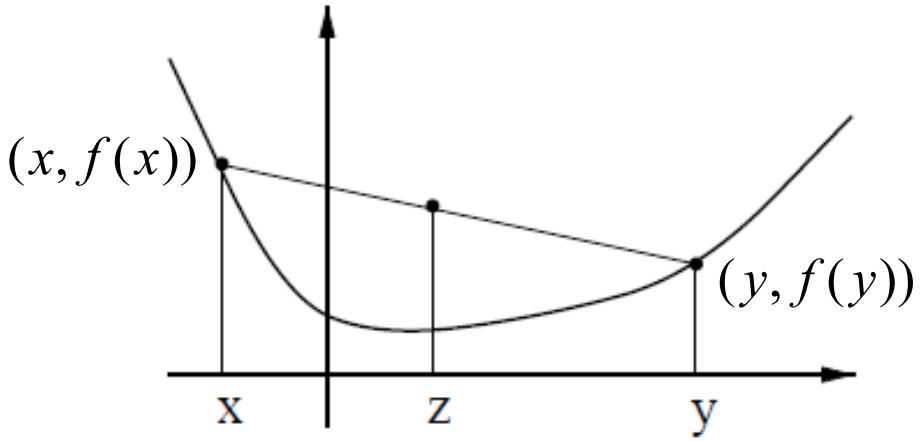
- 凸集合的交运算：令$\{C_i : i \in I\}$是凸集的集合，那么$\cap_{i\in I} C_i$是凸集。
- 凸集合的和运算：令C_1, C_2为凸集合，则$\{x_1+x_2 : x_1 \in C_1, x_2 \in C_2\}$是凸集。
- 仿射函数保凸集：仿射函数$f(x) = Ax + b$，这里，$A \in \mathbb{R}^{m\times n}, b \in \mathbb{R}^m$，有
  - $X \subseteq \mathbb{R}^n$是凸集 $\Longrightarrow$ $f(X) = \{f(x) : x \in X\}$ 是凸集
  - $S \subseteq \mathbb{R}^m$是凸集 $\Longrightarrow$ $f^{-1}(S) = \{x \in R^n : f(x) \in S\}$ 是凸集

凸函数

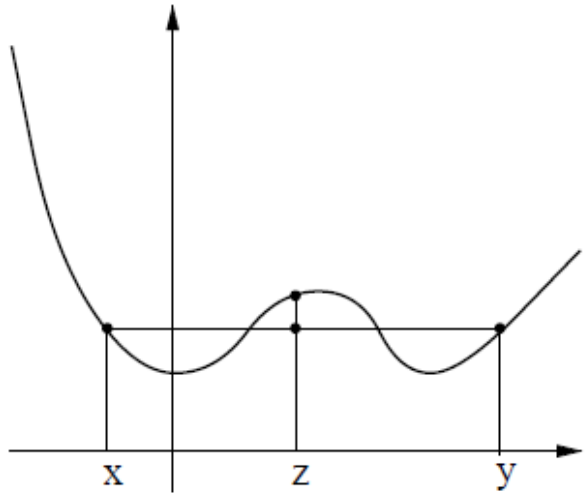
- **凸函数(Convex Function)**：令集合$C \subseteq \mathbb{R}^n$是凸集。$\forall x, y \in C, \forall \lambda \in [0,1]$，如果函数$f: C \to \mathbb{R}$满足

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y)$$

则f为凸函数。



凸函数



非凸函数

- **凸函数**图像上任意两点之间的连线（弦）都在函数图像之上。

凹函数

- **凹函数（Concave Function）的定义：**令集合$C \subseteq \mathbb{R}^n$是凸集。$\forall\, x, y \in C, \forall \lambda \in [0,1]$，如果函数$f: C \to R$满足以下条件

$$f(\lambda x + (1-\lambda)y) \geq \lambda f(x) + (1-\lambda) f(y)$$

则f为凹函数。

- **定理：**函数$f: C \to \mathbb{R}$是凹函数当且仅当函数$-f$是凸函数。

严格凸函数/严格凹函数

严格凸函数（Strictly Convex）的定义：令集合$C \subseteq \mathbb{R}^n$是凸集。$\forall\, x, y \in C$，

$\forall \lambda \in (0,1)$，如果函数$f: C \to \mathbb{R}$满足以下条件

$$f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda) f(y)$$

则f为严格凸函数.

严格凹函数（Strictly Concave）的定义：令集合$C \subseteq \mathbb{R}^n$是一凸集。$\forall\, x, y \in C$，

$\forall \lambda \in (0,1)$，如果函数$f: C \to \mathbb{R}$满足以下条件

$$f(\lambda x + (1-\lambda)y) > \lambda f(x) + (1-\lambda) f(y)$$

则f为严格凹函数.

举例

- 仿射函数$f(x)=Ax+b$既是凸函数，又是凹函数。

  证明：$\forall\, x,y\in\mathbb{R}^n,\forall\lambda\in[0,1]$，有

$$\begin{aligned} f(\lambda x+(1-\lambda)y) &= A(\lambda x+(1-\lambda)y)+b \\ &= \lambda(Ax+b)+(1-\lambda)(Ay+b) \\ &= \lambda f(x)+(1-\lambda)f(y) \end{aligned}$$

- p −范数$f(x)=\|x\|_p(p\geq 1,x\in\mathbb{R}^n)$为凸函数，如$\|x\|_1,\|x\|_2,\|x\|_\infty$。

  证明：根据范数的三角不等式和正齐性，$\forall\, x,y\in\mathbb{R}^n,\forall\lambda\in[0,1]$，有

$$\begin{aligned} f(\lambda x+(1-\lambda)y) &= \|\lambda x+(1-\lambda)y\|_p \\ &\leq \lambda\|x\|_p+(1-\lambda)\|y\|_p \\ &= \lambda f(x)+(1-\lambda)f(y) \end{aligned}$$

作业

证明：最大值函数$f(x)=\max\{x_1,x_2,\cdots,x_n\},x=[x_1,x_2,\cdots,x_n]^\top\in\mathbb{R}^n$为凸函数

- 二次函数$f(x)=\frac{1}{2}x^{\mathsf{T}}Qx+p^{\mathsf{T}}x+r,\ x\in\mathbb{R}^n$是否为凸函数？是否为凹函数？是否为严格凸函数？是否为严格凹函数？

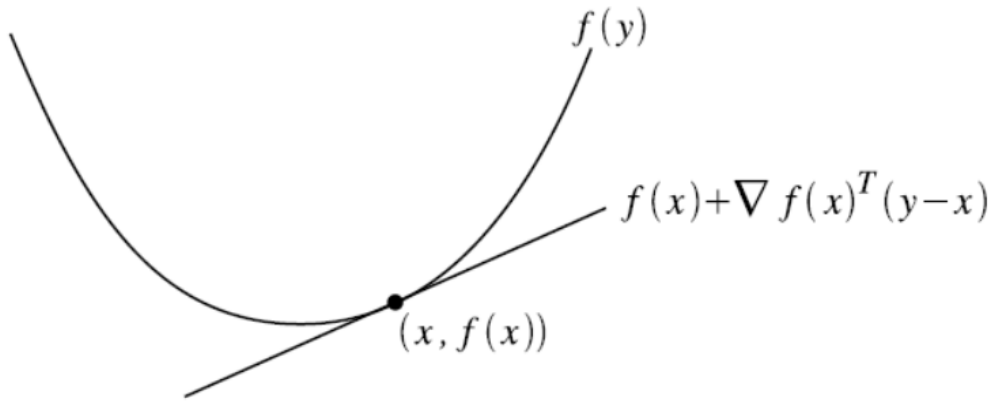
凸函数的一阶判定

- 定理：$C \in \mathbb{R}^n$为凸集且函数$f: C \to \mathbb{R}$在集合C上可微，那么

（1）函数f是凸函数当且仅当$\forall x, y \in C$, 有

$$f(y) \geq f(x) + \nabla^{\mathrm{T}} f(x)(y - x)$$ ← 一阶判定条件

（2）如果$\forall x, y \in C$且$x \neq y$，$f(y) > f(x) + \nabla^{\mathrm{T}} f(x)(y - x)$，那么 函数$f$是严格凸函数。



凸函数的一阶判定

函数f是凸函数当且仅当$\forall x, y \in C$, 有$f(y) \geq f(x) + \nabla^{\mathrm{T}} f(x)(y - x)$

证明：“$\Rightarrow$”：函数f是凸函数，那么$\forall x, y \in C, \forall \lambda \in [0,1]$，那么

$$f(x + \lambda(y - x)) = f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y),$$

因此，有 $\frac{f(x+\lambda(y-x))-f(x)}{\lambda} \leq f(y) - f(x)$。

进一步，因为 $\frac{f(x+\lambda(y-x))-f(x)}{\lambda} \to \nabla^{\mathrm{T}} f(x)(y - x)$当$\lambda \to 0_+$，

所以，$\nabla^{\mathrm{T}} f(x)(y - x) \leq f(y) - f(x)$ 成立。证毕。

凸函数的一阶判定

函数f是凸函数当且仅当$\forall x, y \in C$,有$f(y) \geq f(x) + \nabla^{\top} f(x)(y - x)$

证明：“$\Leftarrow$”：$\forall x, y \in C, \forall \lambda \in [0,1]$，令$z = \lambda x + (1 - \lambda)y$。因为

$x - z = (1 - \lambda)(x - y)$，有

$$f(x) \geq f(z) + \nabla^{\top} f(z)(x - z) = f(z) + \nabla^{\top} f(z)(1 - \lambda)(x - y)\ , \qquad (1)$$

因为$y - z = -\lambda(x - y)$，有

$$f(y) \geq f(z) + \nabla^{\top} f(z)(y - z) = f(z) + \nabla^{\top} f(z)(-\lambda)(x - y)\ , \qquad (2)$$

计算$\lambda * (1) + (1 - \lambda) * (2)$，有

$$\lambda f(x) + (1 - \lambda) f(y) \geq f(z) = f(\lambda x + (1 - \lambda)y)$$

二次函数$f(x)=\frac{1}{2}x^{\mathsf{T}}Qx+p^{\mathsf{T}}x+r,\ x\in\mathbb{R}^n$是否为凸函数？是否为凹函数？是否为严格凸函数？是否为严格凹函数？

凸函数的二阶判定

定理：$C \subseteq \mathbb{R}^n$为凸集（开集）且函数$f: C \to \mathbb{R}$在集合C上二阶连续可微，那么

（1）函数f是凸函数当且仅当$\forall x \in C, \nabla^2 f(x)$为对称半正定矩阵

（2）如果$\forall x \in C, \nabla^2 f(x)$为对称正定矩阵，那么函数$f$是严格凸函数

这里，$\forall x = [x_1, x_2, \cdots, x_n] \in C$, 函数$f$的Hessian矩阵$\nabla^2 f(x) \in \mathbb{R}^{n \times n}$定义为

$$\left(\nabla^2 f(x)\right)_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j} \quad (i, j = 1,2, \cdots, n)$$

凸函数的二阶判定

- 推论：$C \subseteq \mathbb{R}^n$为凸集，二次函数$f: C \to R$定义为$f(x) = \frac{1}{2}x^\top Qx + p^\top x + r$，

  这里，$Q \in S^n$为对称矩阵。那么

  （1）函数f是凸函数当且仅当Q为对称半正定矩阵

  （2）函数f是凹函数当且仅当Q为对称半负定矩阵

  （3）函数f是严格凸（凹）函数当且仅当Q为对称正（负）定矩阵

  （4）否则，函数f为非凸非凹函数

证明：$\forall x \in C$, 函数f的Hessian矩阵为

$$\nabla^2 f(x) = Q$$

举例

- 指数函数$f:\mathbb{R}\to\mathbb{R}, f(x)=e^{ax}, \forall a\in\mathbb{R}$为凸函数，因为$\forall x\in\mathbb{R}$，有

$$f''(x)=a^2e^{ax}>0$$

- 负对数函数 $f, \forall x\in\mathbb{R}_{++}=\{x\in\mathbb{R}: x>0\}, f(x)=-\log x$ 为 凸函数，因为$\forall x\in\mathbb{R}_{++}$，有

$$f''(x)=\frac{1}{x^2}>0$$

- 最小二乘函数$f(x)=\|Ax-b\|_2^2$为凸函数，因为$\forall x\in\mathbb{R}$，有

$$\nabla f(x)=2A^{\mathrm{T}}(Ax-b), \qquad \nabla^2 f(x)=2A^{\mathrm{T}}A$$

凸函数的性质

- 非负乘积保持凸性：$\forall \alpha \geq 0,$如果函数f是定义在C上的凸函数，则函数 $g(x) = \alpha f(x)$ 是凸函数。
- 和运算保持凸性：如果函数 f_1, f_2为凸函数，那么函数$g(x) = f_1(x) + f_2(x)$ 为凸函数。
- $C \subseteq \mathbb{R}^n$为凸集且$\{f_i : C \to \mathbb{R} | i \in I\}$是凸函数的集合，则其非负权重和$f = \sum_{i \in I} w_i f_i$ 是凸函数，其中权重$w_i \geq 0, \forall i \in I$。

凸函数的性质

- f是定义在凸集$C \subseteq \mathbb{R}^n$上的凸函数，则$g: B \to \mathbb{R}, g(x) = f(Ax + b), B = \{Ax + b: x \in C\}$是凸函数。

例如：1. 由于$f(x) = \|x\|$是凸函数，那么，$\|y - Ax\|$也是凸函数。

2. 由于$f_i(x) = -logx \ \ (i = 1,2,\cdots,n)$是凸函数，那么，函数$g: C \to \mathbb{R}$

$$g(x) = -\sum_{i=1}^{m} \log(b_i - a_i^{\top} x)$$

是凸函数，其中，函数g的定义域为：$dom\ g = \{x: a_i^{\top} x < b_i, i = 1,2,\cdots,m\}$.

凸函数的性质

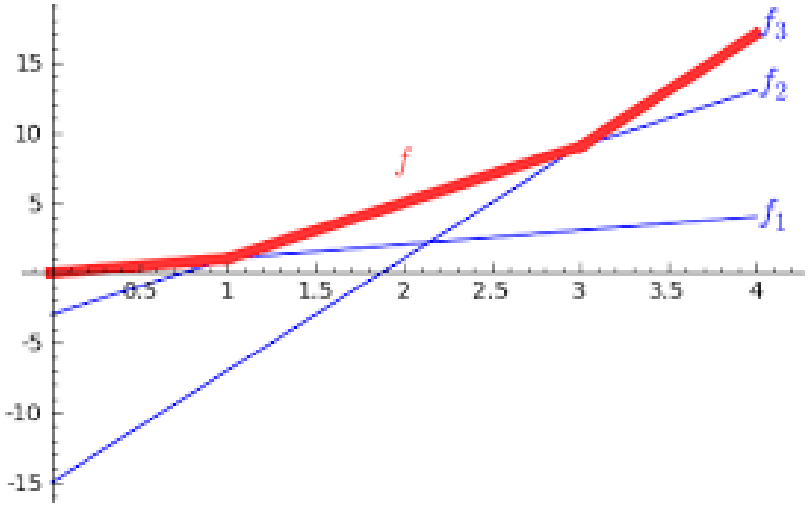
- 令$\{f_i: C \to \mathbb{R} | i \in I\}$为定义在凸集$C \subseteq \mathbb{R}^n$上凸函数的集合，则函数$h: C \to \mathbb{R}$,

$h(x) = \sup_{i \in I} f_i(x)$ 是凸函数。当I是有限指标集合时，

$$h(x) = \sup_{i \in I} f_i(x) = \max\{f_1(x), f_2(x), \cdots, f_n(x)\}$$

- 例如，分段线性函数是凸函数

$$h(x) = \max_{i=1,2,\cdots,n} (a_i^\top x + b_i)$$



凸函数的性质

- 如果对于任意的$y \in A$, $f(x,y)$是关于x的凸函数，那么

$$g(x) = \sup_{y \in A} f(x,y)$$

是凸函数。

例如：1. 集合C的支持函数（Support Function）：$S_C(x) = \sup_{y \in C} y^{\mathsf{T}} x$是凸函数；

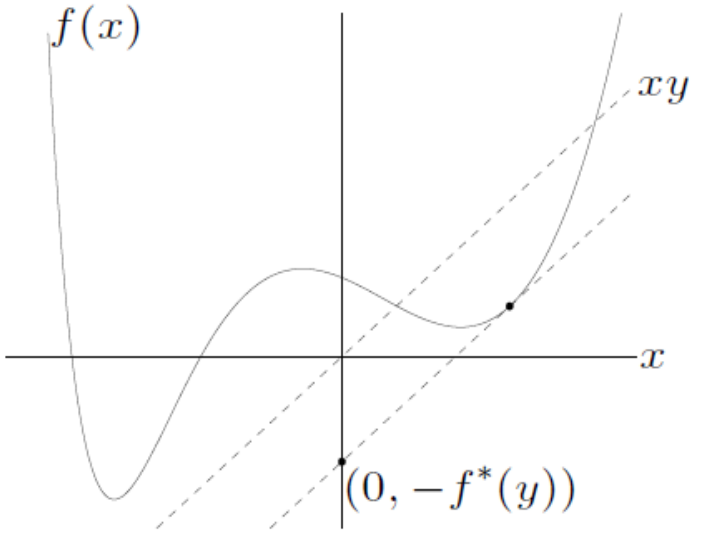
2. 集合C上距离x最远的点：$f(x) = \sup_{y \in C} \|x - y\|$是凸函数；

凸函数的性质

- 如果对于任意的$y \in A, f(x,y)$是关于x的凸函数，那么$g(x) = \sup_{y \in A} f(x,y)$是凸函数。

- 共轭函数：函数$f: \mathbb{R}^n \to \mathbb{R}$的共轭函数$f^*: \mathbb{R}^n \to \mathbb{R}$定义为：仿射函数$y^\top x$与$f(x)$之间的最大差值，即

$$f^*(y) = \sup_{x \in dom\, f} (y^\top x - f(x))$$



https://www.cnblogs.com/bregman/p/17682319.html

- 如果函数f可微，在满足$f'(x) = y$的点x处差值最大。

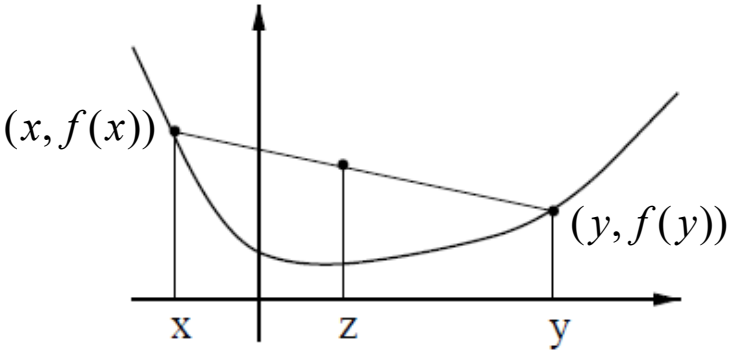
- 对于任意函数f，其共轭函数f^*为凸函数。为什么？

例如：函数$f(x) = -logx$的共轭函数f^*为凸函数，这里

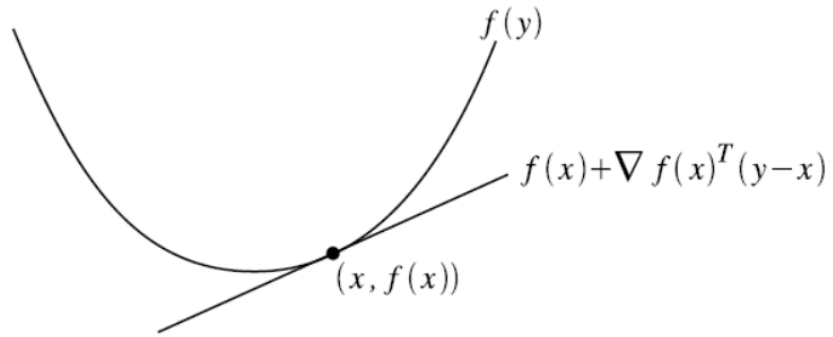
$$f^*(y) = \sup_{x>0}(xy + logx) = \begin{cases} -1 - \log(-y), y < 0 \\ \infty, y \geq 0 \end{cases}$$

凸函数的判定方法总结

- 定义：$f(\lambda x+(1-\lambda)y) \leq \lambda f(x)+(1-\lambda)f(y)$



- 一阶判定：$f(y) \geq f(x)+\nabla^{\mathrm{T}} f(x)(y-x)$



- 二阶判定：$\forall x \in C, \nabla^2 f(x)$对称半正定矩阵

  二次函数$f(x)=\frac{1}{2} x^{\mathrm{T}} Q x+p^{\mathrm{T}} x+r$

- 保凸函数运算

优化问题

优化问题数学标准形式

$$\min_{x} \quad f_0(x) \dashrightarrow \text{目标函数}$$

$$s.t. \quad f_i(x) \le 0 \ (i = 1,2,\cdots,m) \dashrightarrow \text{不等式限制}$$

$$h_j(x) = 0, \ (j = 1,2,\cdots,n) \dashrightarrow \text{等式限制}$$

⇩

可行解集

$$C = \{x \in \mathbb{R}^n : f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$$

⇩

$$\min_{x} \quad f_0(x)$$
$$s.t. \quad x \in C$$

凸优化问题

凸优化问题

$$\min_{x} \quad f_0(x) \longrightarrow \text{目标函数 } f_0: X \to \mathbb{R} \text{为凸函数}$$
$$s.t. \quad x \in C \longrightarrow \text{可行解集} C \text{为凸集合}$$

这里，可行解集$C = \{x \in \mathbb{R}^n : f_i(x) \leq 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$



✓ 什么情况下，可行解集C为凸集合？

✓ 凸优化问题为什么重要？

- 作业：若函数f是定义在凸集X上的凸函数，则对于任意的α，水平集合$X_\alpha = \{x \in X: f(x) \le \alpha\}$为凸集。

可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$

$= \{x \in \mathbb{R}^n: f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) \le 0, h_j(x) \ge 0, j = 1,2,\cdots,n\}$

$= \{x \in \mathbb{R}^n: f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) \le 0, -h_j(x) \le 0, j = 1,2,\cdots,n\}$

- ✓ $f_i(x)(i = 1,2,\cdots,m)$为凸函数
- ✓ $h_j(x)(j = 1,2,\cdots,n)$为凸函数
- ✓ $-h_j(x)(j = 1,2,\cdots,n)$为凸函数

- ✓ $f_i(x)(i = 1,2,\cdots,m)$为凸函数
- ✓ $h_j(x)(j = 1,2,\cdots,n)$为仿射函数

凸优化问题数学标准形式

$$\min_{x} \quad f_0(x)$$ ----------→ 目标函数为凸函数

$$s.t. \quad f_i(x) \leq 0 \ (i = 1,2,\cdots,m)$$ -----→ 不等式限制函数为凸函数

$$h_j(x) = 0, \ (j = 1,2,\cdots,n)$$ -----→ 等式限制函数为仿射函数



✓ 什么情况下，可行解集C为凸集合？

✓ 凸优化问题为什么重要？

凸优化问题为什么重要？

$$\min_{x} \quad f_0(x) \longrightarrow \text{目标函数 } f_0: X \to \mathbb{R} \text{为凸函数}$$
$$s.t. \quad x \in C \longrightarrow \text{可行解集} C \text{为凸集合}$$

- 局部极小解：如果$\exists \epsilon > 0$，使得$\forall x$满足$\|x - \hat{x}\| < \epsilon$，有$f(\hat{x}) \leq f(x)$，$\forall x \in X$，称向量$\hat{x}$为$f$的局部极小解。
- 全局最小解：如果$\forall x \in X$，有$f(\hat{x}) \leq f(x)$成立，称向量$\hat{x}$为f的全局最小解。

定理：凸优化问题局部极小解即全局最小解

凸优化问题为什么重要？

定理：凸优化问题局部极小解即全局最小解

$$\begin{aligned} \min_{x} \quad & f_0(x) \\ s.t. \quad & x \in C \end{aligned}$$

证明：“全局最小解是局部极小解”，显然；

“局部极小解是全局最小解”：（反证法）假设存在$x \in C$是局部极小解，而非全局最小解，那么$\exists y \neq x$ 使得$f(y) < f(x)$. 由于函数f为凸函数，对所有的$\lambda \in [0,1]$, 有

$$\begin{aligned} f\big((1-\lambda)x + \lambda y\big) &\leq (1-\lambda)f(x) + \lambda f(y) \\ &< (1-\lambda)f(x) + \lambda f(x) = f(x). \end{aligned}$$

对于足够小的λ，则 $z = (1-\lambda)x + \lambda y$ 属于x的ϵ −邻域且满足$f(z) < f(x)$. 该结论与$x \in C$是局部极小解相矛盾。证毕。

凸优化问题最优解的性质

- 无限制凸优化问题：$\min \quad f_0(x)$。x^*是最优解，即$x^* = argmin\, f_0(x)$

  当且仅当

$$x^* \in domf_0 \text{ 且 } \nabla f_0(x^*) = 0$$

- 等式限制凸优化问题：$\min \quad f_0(x) \quad s.t. \quad Ax = b$。$x^*$是最优解，即$x^* = argmin\, f_0(x)$

  当且仅当

$$x^* \in domf_0,\ Ax^* = b \text{ 且 } \nabla f_0(x^*) + A^{\mathsf{T}}\nu = 0$$

回顾：凸优化问题

$$\min_{x} \quad f_0(x) \dashrightarrow \text{目标函数为凸函数}$$
$$s.t. \quad f_i(x) \le 0 \ (i = 1,2,\cdots,m) \dashrightarrow \text{不等式限制函数为凸函数}$$
$$h_j(x) = 0, \ (j = 1,2,\cdots,n) \dashrightarrow \text{等式限制函数为仿射函数}$$

$$\min_{x} \quad f_0(x) \longrightarrow \text{目标函数 } f_0: X \to \mathbb{R} \text{为凸函数}$$
$$s.t. \quad x \in C \longrightarrow \text{可行解集} C \text{为凸集合}$$
$$C = \{x \in \mathbb{R}^n : f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$$

- 定理：凸优化问题局部极小解即全局最小解

凸优化问题举例

- 线性规划

$$\begin{aligned} \min \quad & c^{\top}x + d \\ s.t. \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

$P \in S_+^n$为对称半正定矩阵

- 二次规划：

$$\begin{aligned} \min \quad & \frac{1}{2}\, x^{\top}Px + c^{\top}x + d \\ s.t. \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

$P, Q_i (i = 1,2,\cdots,m) \in S_+^n$为对称半正定矩阵

- 二次函数限制的二次规划：

$$\begin{aligned} \min \quad & \frac{1}{2}\, x^{\top}Px + c^{\top}x + d \\ s.t. \quad & \frac{1}{2}\, x^{\top}Q_i x + r_i^{\top}x + s_i \leq 0 \ (i = 1,2,\cdots,m) \\ & Ax = b \end{aligned}$$

凸优化问题举例

- 有限制最小二乘优化问题：

$$\begin{aligned} \min \quad & \frac{1}{2}\|Ax-b\|_2^2 \\ s.t. \quad & l \le x \le u \end{aligned} \quad \Leftrightarrow \quad \begin{aligned} \min \quad & \frac{1}{2}x^\top Px + c^\top x + d \\ s.t. \quad & G(x;x) \le h \end{aligned}$$

这里，$A \in \mathbb{R}^{m\times n}, b \in \mathbb{R}^m$.

- 以上优化问题实际上为二次规划问题

$$P \in \mathbb{R}^{n\times n} = \frac{1}{2}A^T A, \quad c \in \mathbb{R}^n = -b^T A, \quad d \in \mathbb{R} = \frac{1}{2}b^T b,$$

$$G \in \mathbb{R}^{2n\times 2n} = \begin{bmatrix} -I & 0 \\ 0 & I \end{bmatrix}, \quad h \in \mathbb{R}^{2n} = \begin{bmatrix} -l \\ u \end{bmatrix}.$$

凸优化问题举例

- 以下优化问题是凸优化问题吗？为什么？

$$\begin{aligned} \min \quad & x_1^2 + x_2^2 \\ s.t. \quad & \frac{x_1}{1+x_2^2} \leq 0 \\ & (x_1 + x_2)^2 = 0 \end{aligned}$$



$$\begin{aligned} \min \quad & x_1^2 + x_2^2 \\ s.t. \quad & x_1 \leq 0 \\ & x_1 = -x_2 \end{aligned}$$

- 目标函数是凸函数；
- 等式限制不是仿射函数。但其可以等价的改写线性等式限制$x_1 = -x_2$；
- 不等式限制不是凸函数，但其可以等价的改写为$x_1 \leq 0$

优化问题的等价转换

- 凸优化问题一般形式

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & f_0(x) \\ s.t. \quad & f_i(x) \le 0 \ （i = 1,2,\cdots,m） \\ & Ax = b \end{aligned}$$

令$f_0(x) \le t$，则以上优化问题等价于：

$$\begin{aligned} \min_{t\in\mathbb{R},x\in\mathbb{R}^n} \quad & t \\ s.t. \quad & f_0(x) - t \le 0 \\ & f_i(x) \le 0 \ （i = 1,2,\cdots,m） \\ & Ax = b \end{aligned}$$

优化问题的等价转换

□ ℓ_1–范数最小化问题：

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & \|x\|_1 \\ s.t. \quad & Gx \le h \\ & Ax = b \end{aligned}$$

令$|x_i| \le t_i$，则以上优化问题等价于线性规划问题：

$$\begin{aligned} \min_{x,t\in\mathbb{R}^n} \quad & \sum_i t_i \\ s.t. \quad & -t \le x \le t \\ & Gx \le h \\ & Ax = b \end{aligned}$$

这里，$t = [t_1, t_2, \cdots, t_n] \in \mathbb{R}^n$

优化问题的等价转换

- ℓ_∞-范数最小化问题：

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & \|x\|_\infty \\ s.t. \quad & Gx \le h \\ & Ax = b \end{aligned}$$

令$\|x\|_\infty \le t$，以上优化问题等价于线性规划问题：

$$\begin{aligned} \min_{x\in\mathbb{R}^n, t\in\mathbb{R}} \quad & t \\ s.t. \quad & -t\mathbf{1} \le x \le t\mathbf{1} \\ & Gx \le h \\ & Ax = b \end{aligned}$$

这里，$\mathbf{1} = [1,1,\cdots,1]^\top \in \mathbb{R}^n$ 。

优化问题的等价转换

- 定义在(x, y)上的优化问题：

只对变量x有限制

$$\min_{x,y} \quad f_0(x, y)$$
$$s.t. \quad f_i(x) \leq 0 \ （i = 1,2, \cdots, m）$$

令$g_0(x) = \inf_y f_0(x, y)$，则以上优化问题等价于：

$$\min_{x} \quad g_0(x)$$
$$s.t. \quad f_i(x) \leq 0 \ （i = 1,2, \cdots, m）$$

优化问题的等价转换

- 含有仿射函数不等式的优化问题：

$$\begin{aligned}\min_{x}\quad & f_0(x)\\ s.t.\quad & a_i^{\top}x \le b_i \quad (i=1,2,\cdots,m)\end{aligned}$$

逼近

$$\begin{aligned}\min_{x,s}\quad & f_0(x)+\sum_{i=1}^{m}s_i\\ s.t.\quad & a_i^{\top}x \le b_i+s_i \quad (i=1,2,\cdots,m)\\ & s_i \ge 0 \quad (i=1,2,\cdots,m)\end{aligned}$$

增加松弛变量$s_i\ (i=1,2,\cdots,m)$，等价于等式限制优化问题：

$$\begin{aligned}\min_{x,s}\quad & f_0(x)\\ s.t.\quad & a_i^{\top}x+s_i = b_i \quad (i=1,2,\cdots,m)\\ & s_i \ge 0 \quad (i=1,2,\cdots,m)\end{aligned}$$

寻找可行解问题

$$\begin{aligned} \underset{x}{find} \quad & x \\ s.t. \quad & f_i(x) \le 0 \ (i = 1,2,\cdots,m) \\ & h_j(x) = 0, \ (j = 1,2,\cdots,n) \end{aligned}$$

$$\begin{aligned} \min_{x} \quad & f_0(x) \\ s.t. \quad & x \in C \end{aligned}$$

这里，可行解集$C = \{x \in \mathbb{R}^n : f_i(x) \le 0, i = 1,2,\cdots,m; h_j(x) = 0, j = 1,2,\cdots,n\}$

- 该问题可写成特殊情况的优化问题

$$\begin{aligned} \min_{x} \quad & 0 \\ s.t. \quad & f_i(x) \le 0 \ (i = 1,2,\cdots,m) \\ & h_j(x) = 0, \ (j = 1,2,\cdots,n) \end{aligned}$$

此时，如果可行解存在，则最优值$p^* = 0$；否则$p^* = \infty$.