西安交通大学
XI'AN JIAOTONG UNIVERSITY

第三章：无约束凸优化问题

无约束凸优化问题

$$\min \ f(x)$$

- 函数$f: \mathbb{R}^n \to \mathbb{R}$，定义域$dom\ f$;
- 基本假设：函数f是具有连续二阶导数的凸函数。
- 求解最优条件：$\nabla f(x^*) = 0$
- 最优解 $x^* = argmin\ f(x)$
- 最优值 $p^* = f(x^*)$

例子

- 二次规划

$$\min f(x) = \frac{1}{2}x^{\mathsf{T}}Qx + p^{\mathsf{T}}x + r \qquad (1)$$

这里，$dom\ f = \mathbb{R}^n$，$Q \in S_+^n$（对称半正定矩阵集合）。

- 凸函数二阶判定⇒ f为凸函数
- $\nabla f(x) = 0 \Leftrightarrow Qx + p = 0$
  - ✓ 如果$Q \in S_{++}^n$，f是严格凸函数，优化问题（1）有唯一最优解；
  - ✓ 如果$Q \in S_+^n$，方程组$Qx + p = 0$有解时，优化问题（1）有无穷多最优解；
  - ✓ 否则，优化问题（1）无最优解。

例子

- 几何规划$\min f(x) = \log(\sum_{i=1}^{m} \exp(a_i^{\top} x + b_i))$，其中，$dom\, f = \mathbb{R}^n$.
- 函数f是凸函数：凸函数二阶判定⇒ $g(y) = \log(\sum_{i=1}^{m} \exp(y_i))$为凸函数，并且凸函数和仿射函数的复合函数还是凸函数；

$$\nabla f(x) = 0 \Leftrightarrow \frac{1}{\sum_{i=1}^{m} \exp(a_i^{\top} x + b_i)} \sum_{i=1}^{m} \exp(a_i^{\top} x + b_i)\, a_i = 0$$

一般情况下该方程组没有解析解，须使用迭代算法。

- 线性不等式的解析中心点$\min f(x) = -\log \sum_{i=1}^{m} (b_i - a_i^{\top} x)$，其中$dom\, f = \{x | a_i^{\top} x < b_i\}$.
- 函数f是凸函数。因为凸函数二阶判定⇒ $g(y) = -\log(y_i)$为严格凸函数，并且凸函数和仿射函数的复合函数还是凸函数；

$$\nabla f(x) = 0 \Leftrightarrow \sum_{i=1}^{m} \frac{1}{b_i - a_i^{\top} x} a_i = 0$$

采用迭代算法，初始点$x^{(0)}$必须满足严格不等式

$$a_i^{\top} x^{(0)} < b_i \ (i = 1,2,\cdots,\mathrm{m})$$

无约束凸优化问题

$\min\ f(x)$

- 函数$f: \mathbb{R}^n \to \mathbb{R}$，定义域$dom\ f$;
- 基本假设：函数f是具有连续二阶导数的凸函数。
- 最优解 $x^* = argmin\ f(x)$
- 最优值 $p^* = f(x^*)$

□ 无约束最小化方法

✓ 迭代方法求解最优性条件$\nabla f(x^*) = 0$

✓ 初始点$x^0 \in dom\ f$;

✓ 产生序列点$x^k \in dom\ f, k = 0,1,2,\cdots$，使得$f(x^k) \to p^*$;

✓ 水平集合$S = \{x: f(x) \leq f(x^0)\}$是闭集;

强凸性及其含义

$$S = \{x: f(x) \leq f(x^0)\}$$

- 强凸性假设：目标函数f在S上是强凸的，即存在$m > 0$使得$\forall x \in S$， $\nabla^2 f(x) \geq mI$
- 若强凸性假设成立，则$\forall x, y \in S$, $f(y) \geq f(x) + \nabla f(x)^{\mathrm{T}}(y - x) + \frac{m}{2}\|y - x\|_2^2$

证明：$\forall x, y \in S$，存在$z \in [x, y]$, 使得

$$f(y) = f(x) + \nabla f(x)^{\mathrm{T}}(y - x) + \frac{1}{2}(y - x)^{\mathrm{T}}\nabla^2 f(z)(y - x)$$

根据强凸性假设，有

$$f(y) \geq f(x) + \nabla f(x)^{\mathrm{T}}(y - x) + \frac{m}{2}\|y - x\|_2^2$$

（1）$m = 0$时，即凸性的基本不等式；

（2）$m > 0$时，对$f(y)$的下界得到比单独利用凸性更好的结果

回顾：无约束优化问题

$$\min\ f(x)$$

- 函数$f: \mathbb{R}^n \to \mathbb{R}$，定义域$dom\ f$;
- 函数f是具有连续二阶导数的凸函数;
- 最优解 $x^* = argmin\ f(x)$
- 最优值 $p^* = f(x^*)$

- 无约束最小化方法

✓ 相当于迭代方法求解最优性条件$\nabla f(x^*) = 0$

✓ 产生序列点$x^k \in dom\ f, k = 0,1,2,\cdots$，使得$f(x^k) \to p^*$;

✓ 初始点$x^0 \in dom\ f$;

✓ 水平集合$S = \{x: f(x) \leq f(x^0)\}$是闭集;

- 强凸性假设：目标函数f在S上是强凸的，即存在$m > 0$使得$\forall x \in S$， $\nabla^2 f(x) \geq mI$
- 若强凸性假设成立，则$f(y) \geq f(x) + \nabla f(x)^{\mathsf{T}}(y - x) + \frac{m}{2}\|y - x\|_2^2$

（1）$m = 0$时，即凸性的基本不等式;

（2）$m > 0$时，对$f(y)$的下界得到比单独利用凸性更好的结果

强凸性及其含义

$S = \{x: f(x) \le f(x^0)\}$

- 强凸性假设：目标函数f在S上是强凸的，即存在$m > 0$使得$\forall x \in S$，$\nabla^2 f(x) \succeq mI$。
- $f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$

证明：$\forall x, y \in S$，$f(y) \ge f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2}\|y - x\|_2^2$

对任意固定的$x \in S$，为关于y的凸函数。令其关于y求导为零，有

$$\tilde{y} = x - \frac{1}{m}\nabla f(x)$$

$$\ge f(x) + \nabla f(x)^\top (\tilde{y} - x) + \frac{m}{2}\|\tilde{y} - x\|_2^2$$

$$= f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$$

$$f(x) - f(y) \le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

$\forall y \in S$成立

$$f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

- ✓ 最优性条件$\nabla f(x^*) = 0$
- ✓ 任意梯度足够小的点都是近似最优解，即

$$\|\nabla f(x)\|_2 \le (2m\epsilon)^{1/2} \Rightarrow f(x) - p^* \le \epsilon$$

- ✓ 次优性条件（概念上的停止准则）

强凸性及其含义

$$\forall y, \text{有} f(y) \geq f(x) + \nabla f(x)^{\top}(y-x) + \frac{m}{2}\|y-x\|_2^2$$

任意x和最优解x^*之间的距离$\|x-x^*\|_2$正比于$\|\nabla f(x)\|_2$的上界，即

$$\|x-x^*\|_2 \leq \frac{2}{m}\|\nabla f(x)\|_2$$

证明：$p^* = f(x^*) \geq f(x) + \nabla f(x)^{\top}(x^*-x) + \frac{m}{2}\|x-x^*\|_2^2$

$$\geq f(x) - \|\nabla f(x)\|_2\|x-x^*\|_2 + \frac{m}{2}\|x-x^*\|_2^2$$

Cauchy-Schwarz不等式
$|x^{\top}y| \leq \|x\|_2\|y\|_2$

$\forall x$，$p^* - f(x) \leq 0$，则 $-\|\nabla f(x)\|_2\|x-x^*\|_2 + \frac{m}{2}\|x-x^*\|_2^2 \leq 0$

$$\|x-x^*\|_2 \leq \frac{2}{m}\|\nabla f(x)\|_2$$

$\nabla^2 f(x)$的上界

- 假设：目标函数f在S上有上界，即存在$M > 0$使得$\forall x \in S$，有$\nabla^2 f(x) \leq MI$
- $f(x) - p^* \geq \frac{1}{2M}\|\nabla f(x)\|_2^2$

证明：$\forall x, y \in S$，存在$z \in [x, y]$, 使得

$$f(y) = f(x) + \nabla f(x)^{\mathrm{T}}(y - x) + \frac{1}{2}(y - x)^{\mathrm{T}}\nabla^2 f(z)(y - x)$$

$$\Downarrow$$

$$f(y) \leq f(x) + \nabla f(x)^{\mathrm{T}}(y - x) + \frac{M}{2}\|y - x\|_2^2$$

$$\Downarrow$$ 两边对y求极小 . . .

为什么？

$$p^* \leq f(x) - \frac{1}{2M}\|\nabla f(x)\|_2^2$$

$$\Downarrow$$

$$f(x) - p^* \geq \frac{1}{2M}\|\nabla f(x)\|_2^2$$

总结

$$\min\ f(x)$$

- 函数$f: \mathbb{R}^n \to \mathbb{R}$，连续二阶导数的凸函数
- 最优解 $x^* = argmin\, f(x)$
- 最优值 $p^* = f(x^*)$
- 最优性条件$\nabla f(x^*) = 0$

□ 迭代求解x^*

- 初始点$x^0 \in dom\, f$；
- 产生序列点$x^k \in dom\, f, k = 0,1,2,\cdots$，使得
  - $f(x^k) \to p^*$；
- 水平集合$S = \{x: f(x) \le f(x^0)\}$是闭集；

- 强凸性假设：存在$m > 0$满足$\forall x \in S$，$\nabla^2 f(x) \ge mI$

$\forall x, y \in S$ ⇓

$$f(y) \ge f(x) + \nabla f(x)^{\mathrm{T}}(y-x) + \frac{m}{2}\|y-x\|_2^2$$

⇓

$$f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2, \quad \|x^* - x\|_2 \le \frac{2}{m}\|\nabla f(x)\|_2$$

- 假设存在$M > 0$使得$\forall x \in S$，有$\nabla^2 f(x) \le MI$，则 $f(x) - p^* \ge \frac{1}{2M}\|\nabla f(x)\|_2^2$

$$\forall x \in S, mI \le \nabla^2 f(x) \le MI$$

⇓

$$f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2 \le p^* \le f(x) - \frac{1}{2M}\|\nabla f(x)\|_2^2$$

下降方法

$$\min\ f(x)$$

迭代求解最优性条件

$$\nabla f(x^*) = 0$$

- 产生一个优化点列$x^k,\ k = 1,2,\cdots$，其中

$$x^{k+1} = x^k + t^k d^k$$

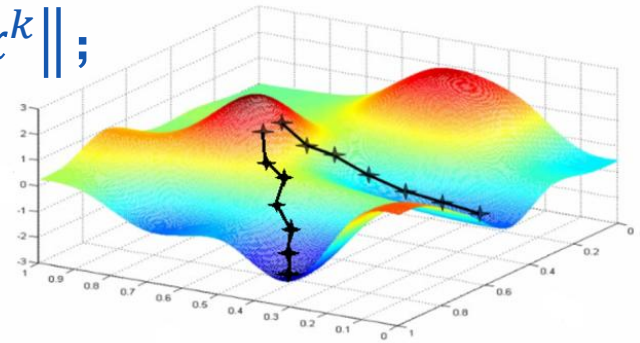
✓ 初始点$x^0 \in dom\ f$; $S = \{x: f(x) \le f(x^0)\}$

✓ 第k次迭代的搜索方向$d^k \in \mathbb{R}^n$，满足$\nabla f(x^k)^{\mathrm{T}} d^k < 0$;

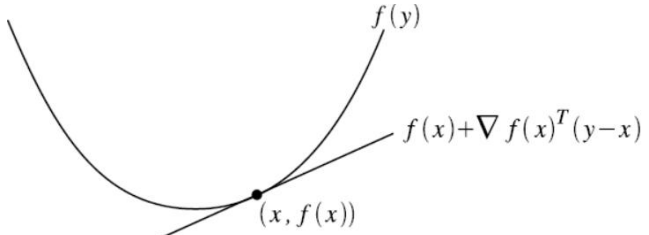
✓ 第k次迭代的步长$t^k \ge 0$(标量)，当$\|d^k\| = 1$，$t^k = \|x^{k+1} - x^k\|$;

✓ 下降方法中，只要x^k不是最优点，则

$$f(x^{k+1}) = f(x^k + t^k d^k) < f(x^k),\ x^k \in S;$$



下降方向充要条件



凸函数一阶条件:$\forall x, y \in dom\ f$

$f(y) \geq f(x) + \nabla f(x)^T(y-x)$

搜索方向d^k为下降方向当且仅当 $\nabla f(x^k)^{\mathrm{T}} d^k < 0$

证明：

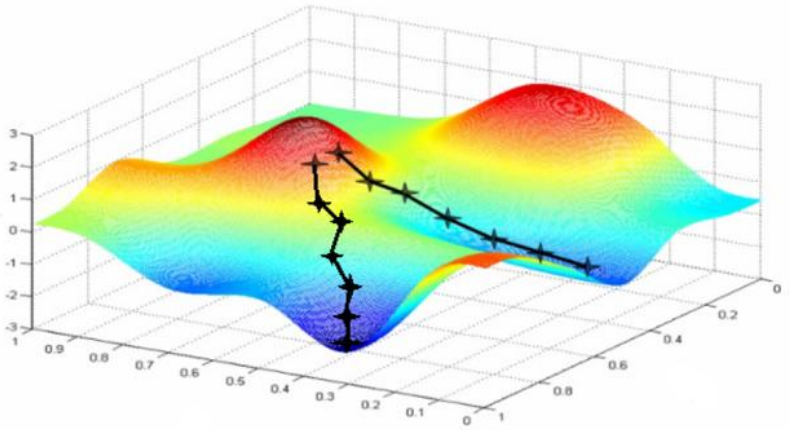
“$\Leftarrow$”：$\nabla f(x^k)^{\mathrm{T}} d^k < 0$，则$\exists \hat{t}$使得$\nabla f(x^k + td^k)^{\mathrm{T}} d^k < 0$，$\forall t \in (0, \hat{t})$，有

$$f(x^k + td^k) \leq f(x^k) + t\nabla f(x^k + td^k)^{\mathrm{T}} d^k < f(x^k)，\ \forall t \in (0, \hat{t})$$

“$\Rightarrow$”:(反证)若 $\nabla f(x^k)^{\mathrm{T}} d^k \geq 0$，则

$$f(x^k + td^k) \geq f(x^k) + t\nabla f(x^k)^{\mathrm{T}} d^k \geq f(x^k)，\ \forall t > 0，\text{矛盾。}$$

通用下降方法



1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 判断是否停止：若$\|\nabla f(x^k)\|_2 \le \varepsilon$，停止
3. 确定x^k处下降方向d^k使满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + td^k) < f(x^k),\ \forall t \in (0, \hat{t})$$

4. 确定步长$t^k > 0$使满足

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

- 判断次优性条件
- $\nabla f(x^k)^{\top} d^k < 0$
- 直线搜索：决定从直线$\{x^k + td^k : t \in \mathbb{R}_+\}$上哪一点开始下步迭代（射线搜索）
- 精确直线搜索和回溯直线搜索。

通用下降方法之精确直线搜索

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 判断是否停止：若$\left\|\nabla f\left(x^k\right)\right\|_2 \leq \varepsilon$，停止
3. 确定x^k处下降方向d^k使满足

$$\exists \hat{t} > 0 \Rightarrow f\left(x^k + td^k\right) < f\left(x^k\right),\ \forall t \in (0, \hat{t})$$

4. 确定步长$t^k > 0$使满足

$$f\left(x^k + t^k d^k\right) < f\left(x^k\right)$$

5. 令$x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

- 精确直线搜索：步长t通过沿着射线$\{x + t\Delta x:\ t \geq 0\}$优化目标函数$f$而确定

$$t = argmin_{s \geq 0} f(x^k + sd^k)$$

- 如果解以上单变量优化问题的计算成本小于计算搜索方向的成本时，适合进行精确直线搜索。

通用下降方法之回溯直线搜索

- 非精确直线搜索方法：沿着射线$\{x^k + td^k: t \geq 0\}$的近似优化目标函数f而确定步长，甚至只要求目标函数f有“足够的减少”即可。

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 判断是否停止：若$\|\nabla f(x^k)\| \leq \varepsilon$，停止
3. 确定x^k处下降方向d^k使满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + td^k) < f(x^k),\ \forall t \in (0, \hat{t})$$

4. 确定步长$t^k > 0$使满足

$$f(x^k + t^k d^k) < f(x^k)$$

5. 令$x^{k+1} = x^k + t^k d^k$，$k \Rightarrow k+1$，回2

回溯直线搜索

4.1 给定f在$x \in domf$处的下降方向d^k，参数
$0 < \alpha < 0.5,\ 0 < \beta < 1$

4.2 $t^k = 1$

4.3 **While** $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^{\mathsf{T}} d^k$
$t^k := \beta t^k$
End

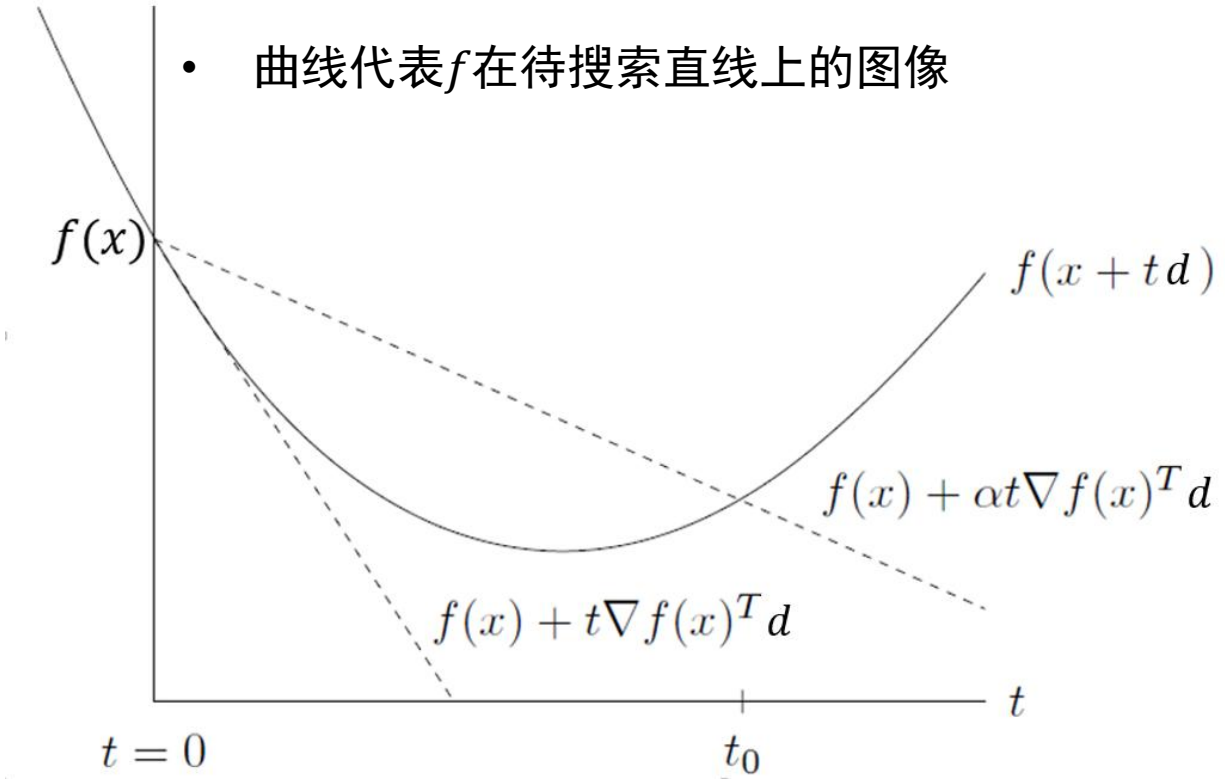
- 回溯直线搜索：从单位步长开始，按比例逐渐缩小，直到满足$f(x^k + t^k d^k) \leq f(x^k) + \alpha t^k \nabla f(x^k)^{\mathsf{T}} d^k$
- d是下降方向，$\nabla f(x)^{\mathsf{T}} d < 0$，只要$t$足够小，就一定有

$$f(x + td) \approx f(x) + t\nabla f(x)^{\mathsf{T}} d < f(x) + \alpha t \nabla f(x)^{\mathsf{T}} d$$

回溯直线搜索方法终会停止

通用下降方法之回溯直线搜索

f在待搜索直线上的图像



- 回溯终止不等式

$$f(x+td) \le f(x)+\alpha t\nabla f(x)^{\mathsf{T}} d$$

将在区间$(0, t_0]$中的某个$t \ge 0$处被满足

- 回溯方法停止时，步长t满足

$$t=1, \quad \text{或者} \quad t \in (\beta t_0, t_0]$$

$$\Downarrow$$

$$t_0 \ge 1$$

- 由回溯直线搜索方法确定的步长

$$t \ge min\{1, \beta t_0\}$$

注意：实际应用中，先通过用β乘以t直到$x+td \in dom\, f$，再开始检测回溯不等式。

通用下降方法之回溯直线搜索

作业：假设函数f是满足$mI \leq \nabla^2 f(x) \leq MI$的强凸函数。令$d$为$x$处的下降方向。证明对于

$$0 < t \leq -\frac{\nabla f(x)^{\mathrm{T}} d}{M\|d\|_2^2}$$

回溯终止条件能够满足。

回顾：通用下降方法

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

通用下降算法

1. 给定初始点 $x^0 \in dom\, f$，令$k=0$

2. 停止条件$\left\|\nabla f(x^k)\right\|_2 \le \varepsilon$

3. 确定x^k处下降方向d^k使满足$\exists \hat{t}>0$,

$$f(x^k+td^k)<f(x^k),\ \forall t\in(0,\hat{t})$$

4. 直线搜索：确定步长$t^k>0$使

$$f(x^k+t^kd^k)<f(x^k)$$

5. $x^{k+1}=x^k+t^kd^k$，$k=k+1$，回2

- 从初始点$x^0 \in dom\, f$出发，产生一组优化点列

  $x^k,(k=1,2,\cdots)$满足 $x^{k+1}=x^k+t^kd^k$

  $f(x^{k+1})<f(x^k)$，$x^k\in S=\{x: f(x)\le f(x^0)\}$

- $\forall x\in S,\ \nabla^2 f(x)\ge mI$,

$$f(x)-p^*\le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

  - 搜索方向d^k

为下降方向当且仅当 $\nabla f(x^k)^{\mathsf{T}}d^k<0$

- 射线$\{x^k+td^k:\ t\in\mathbb{R}_+\}$搜索

✓ 精确直线搜索

✓ 回溯直线搜索

回顾：通用下降方法

$\min\ f(x)$

⬇

迭代求解最优性条件$\nabla f(x^*)=0$

- 从初始点$x^0 \in dom\, f$出发，产生一组优化点列$x^k, (k=1,2,\cdots)$满足

$$x^{k+1}=x^k+t^k d^k,\ f(x^{k+1})<f(x^k),\ x^k \in S=\{x: f(x)\le f(x^0)\}$$

通用下降算法

1. 给定初始点 $x^0 \in dom\, f$，令$k=0$
2. 停止条件$\|\nabla f(x^k)\| \le \varepsilon$
3. 确定x^k处下降方向d^k使满足$\exists \hat{t}>0,$

$$f(x^k+td^k)<f(x^k),\ \forall t\in(0,\hat{t})$$

4. 直线搜索：确定步长$t^k>0$使

$$f(x^k+t^k d^k)<f(x^k)$$

5. $x^{k+1}=x^k+t^k d^k$，$k=k+1$，回2

- ✓ 搜索方向d^k为下降方向当且仅当$\nabla f(x^k)^{\top} d^k<0$；
- ✓ 搜索步长$t^k \ge 0$(标量)；

➢ 精确直线搜索：$t=argmin_{s\ge 0} f(x+sd)$

➢ 回溯直线搜索

4.1 $0<\alpha<0.5,\ 0<\beta<1,\ t=1$

4.2 **While** $f(x+td^k)>f(x)+\alpha t\nabla f(x)^{\top} d^k$,

$t:=\beta t$

End

梯度下降方法及收敛性

下降方向满足： $\nabla f(x^k)^T d^k < 0$

1. 给定初始点 $x^0 \in dom\, f$，令 $k = 0$
2. 判断是否停止：如果 $\|\nabla f(x^k)\|_2 \leq \varepsilon$，停止
3. $d^k = -\nabla f(x^k)$
4. 直线搜索：确定 $t^k > 0$ 满足

$$f(x^k + t^k d^k) < f(x^k)$$

5. 更新 $x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

负梯度方向：$d^k = -\nabla f(x^k)$

$$\nabla f(x^k) \neq 0$$

$$\Rightarrow \nabla f(x^k) d^k = -\|\nabla f(x^k)\|_2^2 < 0$$

⇒负梯度方向为“天然”下降方向

梯度下降方法及收敛性

➢ 回溯直线搜索

4.1 $0 < \alpha < 0.5, 0 < \beta < 1, t = 1$

4.2 **While** $f(x + td^k) > f(x) + \alpha t \nabla f(x)^\top d^k$,

$t := \beta t$

End

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 判断是否停止：如果$\|\nabla f(x^k)\|_2 \leq \varepsilon$，停止
3. $d^k = -\nabla f(x^k)$
4. 直线搜索：确定$t^k > 0$满足

$$f(x^k + t^k d^k) < f(x^k)$$

更新$x^{k+1} = x^k + t^k d^k$，$k \Rightarrow k+1$，回2

✓ 回溯直线搜索

4.1 $0 < \alpha < 0.5,\ 0 < \beta < 1,\ t^k = 1$

4.2 **While** $f(x^k - t^k \nabla f(x^k)) > f(x^k) - \alpha t^k \|\nabla f(x^k)\|_2^2$

$t^k := \beta t^k$

End

✓ 精确直线搜索：

$$t^k = argmin_{s \geq 0} f(x^k - s\nabla f(x^k))$$

收敛性如何确定？

梯度下降方法及收敛性-精确直线搜索

$$\min\ f(x)$$

⬇

迭代求解最优性条件$\nabla f(x^*)=0$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in dom\ f$，令$k=0$

2. 停止条件$\|\nabla f(x^k)\|_2 \le \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 精确直线搜索：

$$t^k = argmin_{s\ge 0} f(x^k + sd^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k=k+1$，回2

- 负梯度方向$d^k = -\nabla f(x^k)$为“天然”下降方向

$$\nabla f(x^k)d^k = -\|\nabla f(x^k)\|^2 < 0$$

- 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

- 目标值与最优值间偏差的上界

$$f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|^2$$

与下降方向无关

- 每次迭代目标改进值下界

$$f(x^k) - f(x^{k+1}) \ge \frac{1}{2M}\|\nabla f(x^k)\|^2$$

$$f(x^K) - p^* \le \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

几何数列

- 算法收敛时，迭代次数的上界

$$f(x^K) - p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0) - p^*)/\varepsilon\right)}{\log(1/c)}$$，这里$c = 1 - \frac{m}{M}$

梯度下降方法及收敛性-精确直线搜索

- 假设f是S上的强凸函数，因此存在m, M满足$mI \leq \nabla^2 f(x) \leq MI \ (\forall x \in S)$.

梯度下降采用精确直线搜索：$f\left(x^k\right) - f\left(x^{k+1}\right) \geq \frac{1}{2M}\left\|\nabla f\left(x^k\right)\right\|_2^2$

证明：

$$f\left(x^k - t\nabla f\left(x^k\right)\right) \leq f\left(x^k\right) - t\left\|\nabla f\left(x^k\right)\right\|_2^2 + \frac{Mt^2}{2}\left\|\nabla f\left(x^k\right)\right\|_2^2$$

梯度下降精确直线搜索：

$t = argmin_{s\geq 0} f\left(x^k - s\nabla f\left(x^k\right)\right)$

两边同时关于t求最小

关于t的二次函数求最小：

$t = \frac{1}{M}$

$$f\left(x^{k+1}\right) \leq f\left(x^k\right) - \frac{1}{2M}\left\|\nabla f\left(x^k\right)\right\|_2^2$$

梯度下降方法及收敛性-精确直线搜索

- 利用目标值和最优值之间偏差的上界: $f(x)-p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$ 及每次迭代目标函数改进值的下界: $f(x^k) \ge f(x^{k+1}) + \frac{1}{2M}\|\nabla f(x^k)\|_2^2$，有

$\|\nabla f(x)\|_2^2 \ge 2m(f(x)-p^*)$

$$f(x^k)-p^* \ge f(x^{k+1})-p^* + \frac{m}{M}(f(x^k)-p^*)$$

$$\Rightarrow f(x^{k+1})-p^* \le \left(1-\frac{m}{M}\right)(f(x^k)-p^*)$$

$$\Rightarrow \quad f(x^K)-p^* \le \left(1-\frac{m}{M}\right)^K (f(x^0)-p^*)$$

$$0 < 1-\frac{m}{M} < 1$$

$$f(x^K) \to p^* \ as \ K \to \infty$$

$$f(x^K)-p^* \le \varepsilon \quad \Rightarrow \quad K \ge \frac{\log((f(x^0)-p^*)/\varepsilon)}{|\log(1-\frac{m}{M})|}$$

迭代次数的上界：至多经过K次迭代可满足$f(x^K)-p^* \le \varepsilon$

梯度下降方法及收敛性-精确直线搜索

精确直线搜索的梯度下降方法迭代次数的上界

$$K \geq \frac{\log((f(x^0)-p^*)/\varepsilon)}{|\log(1-\frac{m}{M})|}$$

分子: 初始次优性和最终次优性的比值的对数

分母: $|\log\left(1-\frac{m}{M}\right)| = -\log(1-\frac{m}{M}) \approx \frac{m}{M}$

- 初始次优性：$\log((f(x^0)-p^*)/\varepsilon)$，即$f(x^0)$和最优值$p^*$之间的缺口；
- 最终次优性：$f(x^K)-p^* \leq \varepsilon$，即$f(x^K)$和最优值$p^*$之间的缺口；
- 所需要迭代次数依赖于初始点的质量和对最终解的精度要求；
- 迭代次数的上界将随着$\frac{M}{m}$的增大而近似线性的增大。

梯度下降方法及收敛性-精确直线搜索

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in dom\ f$，令$k=0$

2. 停止条件$\|\nabla f(x^k)\|_2 \le \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 精确直线搜索：

$$t^k = argmin_{s\ge 0} f(x^k + s d^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k=k+1$，回2

✓ 负梯度方向$d^k = -\nabla f(x^k)$为“天然”下降方向

$$\nabla f(x^k) d^k = -\|\nabla f(x^k)\|^2 < 0$$

✓ 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

- 目标值与最优值间偏差的上界

$$f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|^2$$

与下降方向无关

- 每次迭代目标改进值下界

$$f(x^k) - f(x^{k+1}) \ge \frac{1}{2M}\|\nabla f(x^k)\|^2$$

$$f(x^K) - p^* \le \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

几何数列

- 算法收敛时，迭代次数的上界

$$f(x^K) - p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0) - p^*)/\varepsilon\right)}{\log(1/c)}$$，这里$c = 1 - \frac{m}{M}$

梯度下降方法及收敛性-回溯直线搜索

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

梯度下降回溯直线搜索算法

1.给定初始点 $x^0 \in dom\, f$，令$k=0$

2.停止条件$\|\nabla f(x^k)\| \le \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 回溯直线搜索：$0<\alpha<0.5,\ 0<\beta<1, t^k=1$

While $f(x^k+t^k d^k) > f(x^k)+\alpha t^k \nabla f(x^k)^{\top} d^k$,

$t^k := \beta t^k$

End

5. $x^{k+1}=x^k+t^k d^k$，$k=k+1$，回2

✓ 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

- 目标值与最优值间偏差的上界

$$f(x)-p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

- 每次迭代目标改进值下界

$$f(x^{k+1}) \le f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\}\|\nabla f(x^k)\|_2^2$$

- 算法收敛时，迭代次数的上界

$$f(x^K)-p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0)-p^*)/\varepsilon\right)}{\log(1/c)}$$

这里，$c=\left(1-\min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

梯度下降方法及收敛性-回溯直线搜索

- 梯度下降方法中采用回溯直线搜索时，只要$0 \le t \le \frac{1}{M}$就能满足回溯停止条件

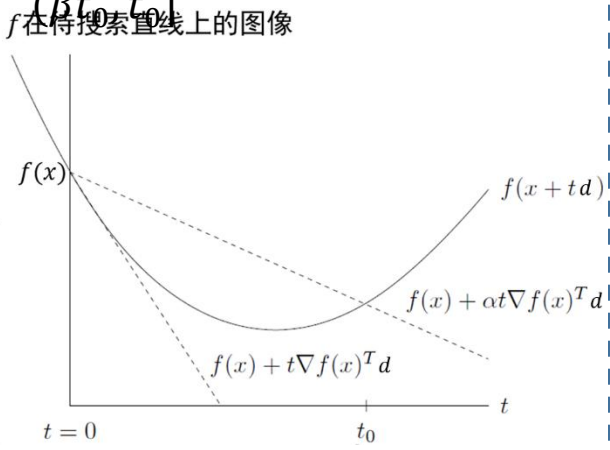
$$f\left(x^k - t\nabla f(x^k)\right) \le f(x^k) - \alpha t\left\|\nabla f(x^k)\right\|_2^2$$

证明：
$$f\left(x^k - t\nabla f(x^k)\right) \le f(x^k) - t\left\|\nabla f(x^k)\right\|_2^2 + \frac{Mt^2}{2}\left\|\nabla f(x^k)\right\|_2^2$$

$$\le f(x^k) - \frac{t}{2}\left\|\nabla f(x^k)\right\|_2^2 \quad \Leftarrow 0 \le t \le \frac{1}{M}$$

$$\le f(x^k) - \alpha t\left\|\nabla f(x^k)\right\|_2^2 \quad \Leftarrow \alpha \in \left(0, \frac{1}{2}\right)$$

回溯方法停止时，步长t满足$t = 1$,或者$t \in (\beta t_0, t_0]$



推论：梯度下降方法中回溯直线搜索将终止于$t = 1$或者$t \ge \frac{\beta}{M}$。

梯度下降方法及收敛性-回溯直线搜索

- 梯度下降方法中回溯直线搜索将终止于$t=1$或者$t \geq \frac{\beta}{M}$
  - ✓ $t=1$时，$f(x^{k+1}) \leq f(x^k) - \alpha\|\nabla f(x^k)\|_2^2$
  - ✓ $t \geq \frac{\beta}{M}$时，$f(x^{k+1}) \leq f(x^k) - \frac{\beta\alpha}{M}\|\nabla f(x^k)\|_2^2$

4. 回溯直线搜索：$0<\alpha<0.5, 0<\beta<1, t^k=1$

While $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^{\mathsf{T}} d^k$,

$t^k := \beta t^k$

End

- 梯度下降方法回溯直线搜索时

$$f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\}\|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq f(x^k) - p^* - \min\{\alpha, \frac{\beta\alpha}{M}\}\|\nabla f(x^k)\|_2^2$$

$$f(x^k) - p^* \leq \frac{1}{2m}\|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)(f(x^k) - p^*)$$

$$1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\} < 1$$

$$f(x^k) - p^* \leq \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)^k (f(x^0) - p^*)$$

几何数列

梯度下降方法及收敛性-回溯直线搜索

- 利用目标函数值和最优值间偏差的上界$f(x)-p^* \le \frac{1}{2m}\left\|\nabla f(x^k)\right\|_2^2$及每次迭代目标函数改进值的下界$f(x^{k+1}) \le f(x^k)-\min\{\alpha,\frac{\beta\alpha}{M}\}\left\|\nabla f(x^k)\right\|_2^2$，有

$$f\left(x^k\right)-p^* \le \left(1-\min\left\{2m\alpha,\frac{2\beta\alpha m}{M}\right\}\right)^k\left(f(x^0)-p^*\right)$$

- 算法收敛时，迭代次数的上界

$$f(x^K)-p^* \le \varepsilon \quad \Longrightarrow \quad K \ge \frac{\log\left((f(x^0)-p^*)/\varepsilon\right)}{\log(1/c)}$$

这里，$c=\left(1-\min\left\{2m\alpha,\frac{2\beta\alpha m}{M}\right\}\right)$

梯度下降方法及收敛性

$\min\ f(x)$

⬇

迭代求解最优性条件$\nabla f(x^*) = 0$

- 从初始点$x^0 \in dom\, f$出发，产生一组优化点列$x^k, (k = 1,2,\cdots)$满足

$$x^{k+1} = x^k + t^k d^k,\ f(x^{k+1}) < f(x^k),\ x^k \in S = \{x: f(x) \le f(x^0)\}$$

梯度下降算法

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 停止条件$\|\nabla f(x^k)\| \le \varepsilon$
3. 下降方向$d^k = -\nabla f(x^k)$
4. 直线搜索：确定$t^k > 0$使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

- 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

使$f(x^K) - p^* \le \varepsilon$成立的$K$只需要满足以下条件：

$$f(x^K) - p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0) - p^*)/\varepsilon\right)}{\log(1/c)}$$

✓ 采用精确直线搜索时$c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时$c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

回顾——梯度下降方法及收敛性

$\min\ f(x)$

⬇

迭代求解最优性条件$\nabla f(x^*) = 0$

- 从初始点$x^0 \in dom\, f$出发，产生一组优化点列$x^k, (k = 1,2,\cdots)$满足

$$x^{k+1} = x^k + t^k d^k,\ f(x^{k+1}) < f(x^k),\ x^k \in S = \{x: f(x) \le f(x^0)\}$$

梯度下降算法

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 停止条件$\|\nabla f(x^k)\| \le \varepsilon$
3. 下降方向$d^k = -\nabla f(x^k)$
4. 直线搜索：确定$t^k > 0$使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

- 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

使$f(x^K) - p^* \le \varepsilon$成立的$K$只需要满足以下条件：

$$f(x^K) - p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0) - p^*)/\varepsilon\right)}{\log(1/c)}$$

✓ 采用精确直线搜索时$c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时$c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

例1 两个变量的二次规划问题：$\min f(x)=\frac{1}{2}(x_1^2+\gamma x_2^2)$，$\gamma>0$，最优解$x^*=(0,0)$。

- 其Hessian矩阵$\nabla^2 f(x)$是常值，其特征值为1和γ，则 $\frac{M}{m}=\frac{\max\{1,\gamma\}}{\min\{1,\gamma\}}=\max\left\{\gamma,\frac{1}{\gamma}\right\}$
- 采用精确直线搜索梯度下降：选初始值$x^0=(\gamma,1)$，第k次迭代时 $\nabla f(x^k)=\begin{bmatrix}x_1^k\\ \gamma x_2^k\end{bmatrix}$
- 确定精确搜索下降步长：$t=arg\min_{t>0} f\left(x^k-t\nabla f(x^k)\right)=\frac{2}{1+\gamma}$

$$x^k=x^{k-1}-t\nabla f(x^{k-1})$$

$$=\begin{bmatrix}(1-t)x_1^{k-1}\\ (1-\gamma t)x_2^{k-1}\end{bmatrix}$$

$$=\left(\frac{\gamma-1}{\gamma+1}\right)\begin{bmatrix}x_1^{k-1}\\ -x_2^{k-1}\end{bmatrix}$$

$$=\left(\frac{\gamma-1}{\gamma+1}\right)^k\begin{bmatrix}\gamma\\ (-1)^k\end{bmatrix}$$

$$x_1^k=\gamma\left(\frac{\gamma-1}{\gamma+1}\right)^k$$

$$x_2^k=\left(-\frac{\gamma-1}{\gamma+1}\right)^k$$

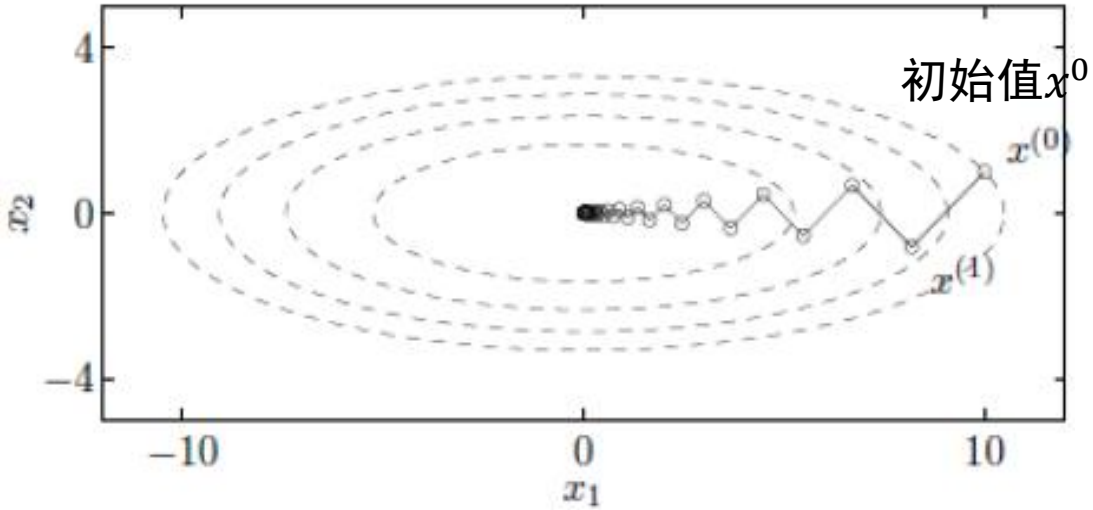
$$f(x^k)=\frac{\gamma(\gamma+1)}{2}\left(\frac{\gamma-1}{\gamma+1}\right)^{2k}=\left(\frac{\gamma-1}{\gamma+1}\right)^{2k}f(x^0)$$

每次迭代收缩因子

例1 两个变量的二次规划问题：$\min f(x)=\frac{1}{2}(x_1^2+\gamma x_2^2)$，$\gamma>0$，最优解$x^*=(0,0)$。

$$x^k=\left(\frac{\gamma-1}{\gamma+1}\right)^k\begin{bmatrix}\gamma\\(-1)^k\end{bmatrix}$$

- 其Hessian矩阵$\nabla^2 f(x)$是常值，其特征值为1和γ，则 $\frac{M}{m}=\frac{\max\{1,\gamma\}}{\min\{1,\gamma\}}=\max\left\{\gamma,\frac{1}{\gamma}\right\}$
- $\gamma=1$时，一次迭代可得到最优解；
- 对于γ离1不远的情况，如$\frac{1}{3}$和3之间，收敛速度很快
- 如果$\gamma\gg 1$或$\gamma\ll 1$时，收敛速度将会非常慢



$\gamma=10$时迭代过程

作业：编程证明以上结论

回顾——梯度下降方法及收敛性

$\min\ f(x)$

⬇

迭代求解最优性条件$\nabla f(x^*) = 0$

- 从初始点$x^0 \in dom\, f$出发，产生一组优化点列$x^k, (k = 1,2,\cdots)$满足

$$x^{k+1} = x^k + t^k d^k,\ f(x^{k+1}) < f(x^k),\ x^k \in S = \{x: f(x) \le f(x^0)\}$$

梯度下降算法

1. 给定初始点 $x^0 \in dom\, f$，令$k = 0$
2. 停止条件$\|\nabla f(x^k)\| \le \varepsilon$
3. 下降方向$d^k = -\nabla f(x^k)$
4. 直线搜索：确定$t^k > 0$使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$，$k = k + 1$，回2

- 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

使$f(x^K) - p^* \le \varepsilon$成立的$K$只需要满足以下条件：

$$f(x^K) - p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0) - p^*)/\varepsilon\right)}{\log(1/c)}$$

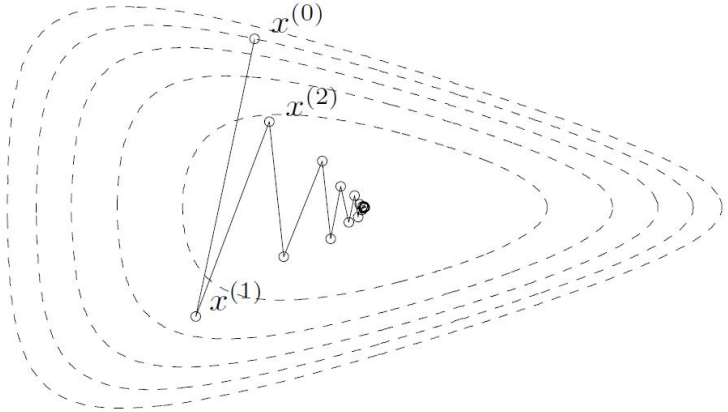
✓ 采用精确直线搜索时$c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时$c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

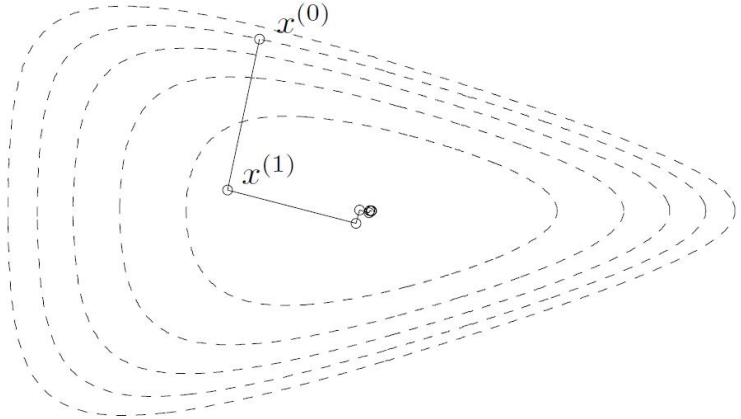
例2 $\mathbb{R}^2$空间非二次规划问题 $\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$

- 回溯直线搜索梯度方法，令 $\alpha = 0.1$，$\beta = 0.7$

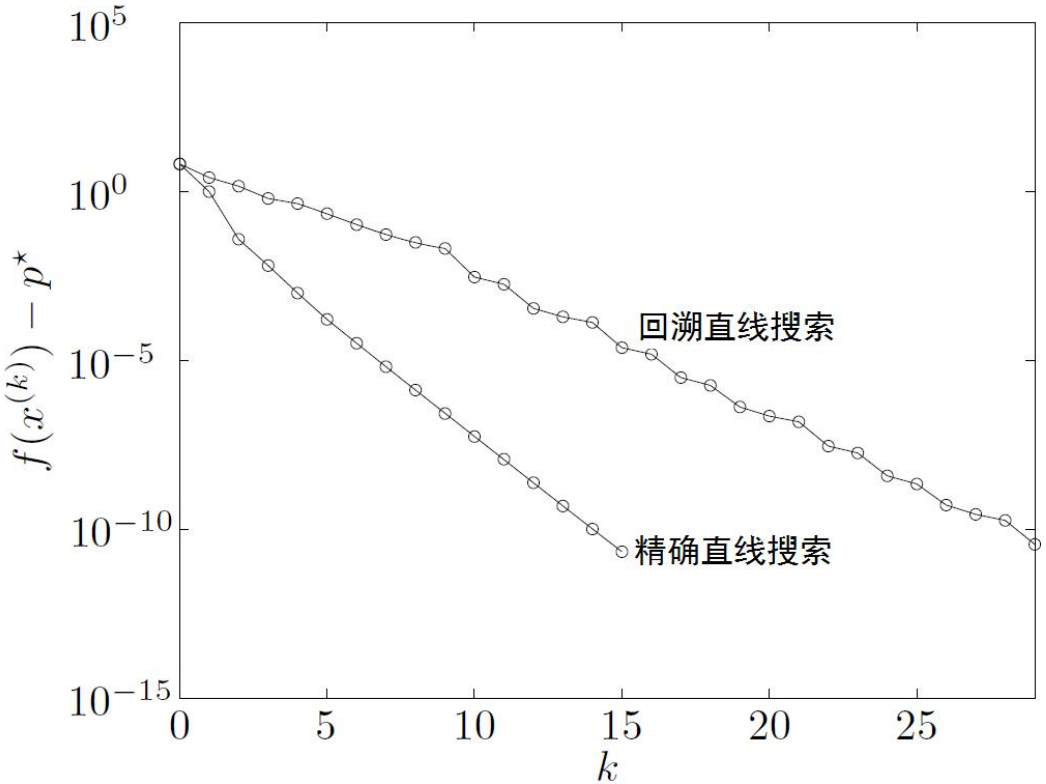
$$x^{k+1} = x^k - t^k \nabla f(x^k)$$



回溯直线搜索梯度方法目标函数迭代过程



精确直线搜索梯度方法目标函数迭代过程



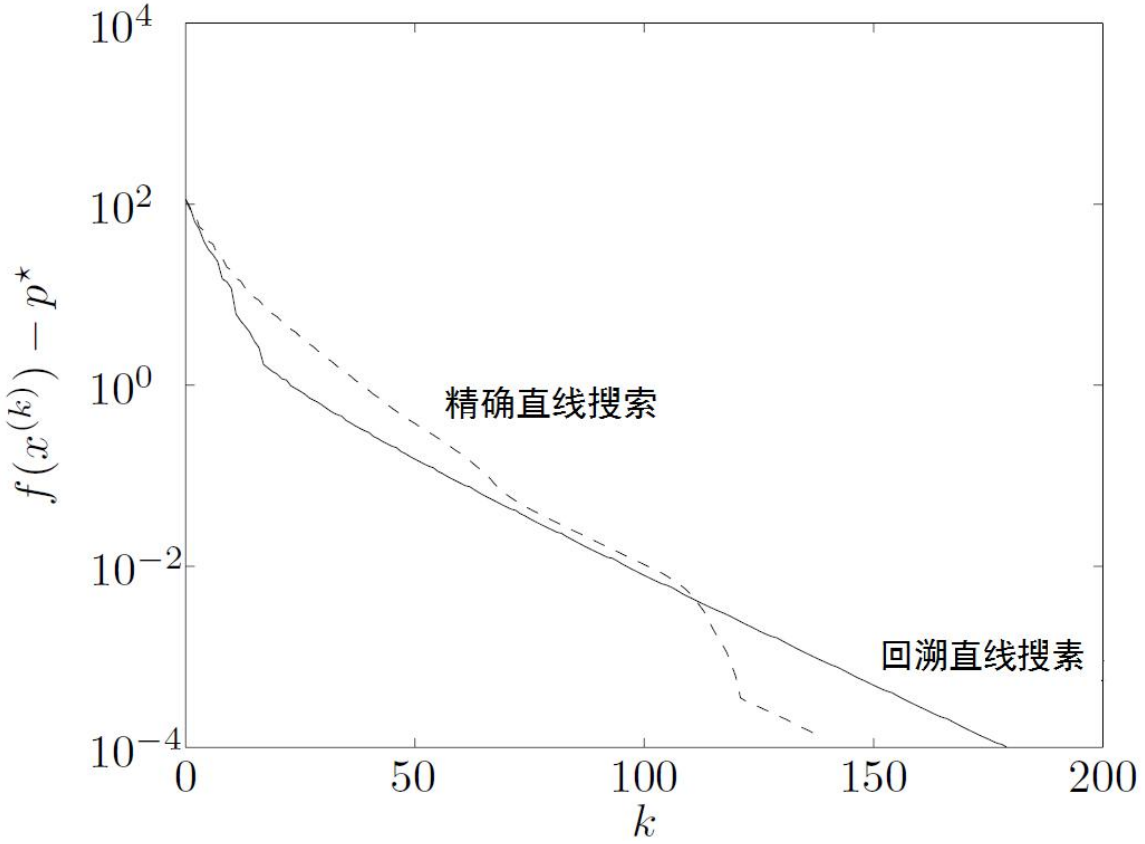
直线搜索的迭代误差随迭代次数改变

例3

$\mathbb{R}^{100}$维空间优化问题

$$\min f(x) = c^T x - \sum_{i=1}^{500} \log\left(b_i - a_i^T x\right), \quad x \in \mathbb{R}^{100}$$

- ✓ 回溯直线搜索$\alpha = 0.1$，$\beta = 0.5$;
- ✓ 精确直线搜索



直线搜索的迭代误差随迭代次数改变

关于梯度下降法算法的若干结论

- 梯度方法通常呈现近似线性收敛性质，即误差 $f(x^k) - p^*$ 以类似于几何数列的方式收敛于零。
- 回溯参数 α, β 的取值对收敛性有明显的影响，但不会产生戏剧性效果。
- 精确直线搜素有时可以改变梯度方法的收敛性，但是效果不是很大。实际上，其或许不能抵消进行精确直线搜素增加的计算量；
- 收敛速度强烈依赖于Hessian矩阵的条件数，即其最小最大特征根的比值。

大作业

对于$\mathbb{R}^2$空间非二次规划问题 $\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$，编程采用负梯度方法进行求解，分别使用精确直线搜索和回溯直线搜索方法，并分析回溯直线搜索采用不同的α, β值时，误差随迭代次数改变的情况。注：初始值相同。

牛顿方法

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*) = 0$

- 牛顿方向：

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k)$$，这里，$\nabla^2 f(x^k) \epsilon S_{++}^n$，$\nabla f(x^k) \neq 0$

- 牛顿方向是下降方向，因为：

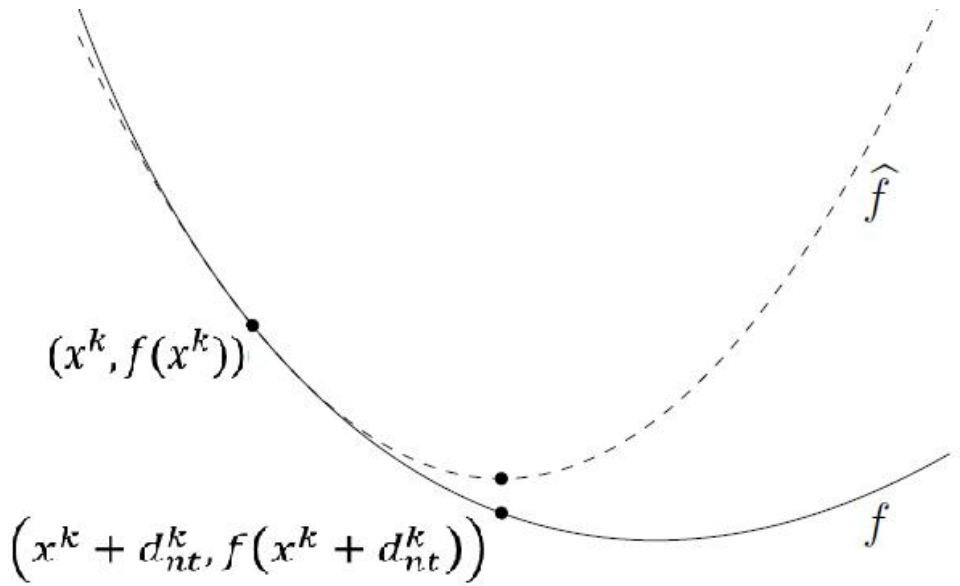
$$\nabla f(x^k)^\top d_{nt}^k = -\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1}\nabla f(x^k) < 0$$

牛顿方向的理解1：二阶近似的最优解

- 目标函数f在x处二阶Taylor近似模型：$\hat{f}(x+v)=f(x)+\nabla f(x)^{\mathrm{T}}v+\frac{1}{2}v^{\mathrm{T}}\nabla^2 f(x)v$

$$\begin{aligned}&\operatorname*{argmin}_v \hat{f}(x^k+v)\\ &=-\nabla^2 f(x^k)^{-1}\nabla f(x^k)\\ &=d_{nt}^k\end{aligned}$$

关于v的二次凸函数，在$v=-\nabla^2 f(x^k)^{-1}\nabla f(x^k)$处达到最小值。



- 当x^k靠近x^*时，点$x^k+d_{nt}^k$是最优解x^*一个很好的估计值
  - ✓ 若f为二次函数，则$x^k+d_{nt}^k$是f的精确最优解；
  - ✓ 若f为近似二次函数，$x^k+d_{nt}^k$是x^*一个很好的估计值；
  - ✓ f是二次可微的，当x靠近x^*时f的二次模型应该非常准确。

牛顿方向的理解2：线性化最优性条件的解

$\min\ f(x)$

迭代求解最优性条件$\nabla f(x^*) = 0$

- f是二次可微的，在x^k附近对最优性条件$\nabla f(x^*) = 0$进行线性化，即：

$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0$$

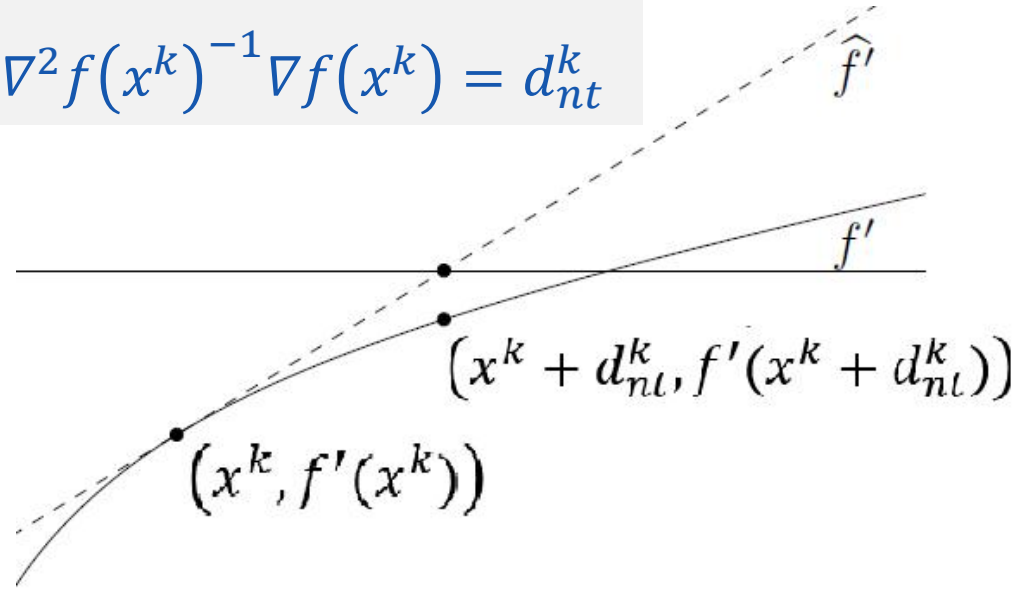
令 $\widehat{f'}(v) = \nabla f(x^k) + \nabla^2 f(x^k) v$

关于v的线性方程，其解为

$$v = -\nabla^2 f(x^k)^{-1} \nabla f(x^k) = d_{nt}^k$$

- 对于x^*附近的x^k（此时最优性条件接近成立）

  加上牛顿步径d_{nt}^k就能满足线性化的最优性条件；



牛顿方法的理解：对于x^*附近的x^k，修正量$x^k + d_{nt}^k$是x^*的一个很好的近似值

牛顿（Newton）减少量

牛顿方向

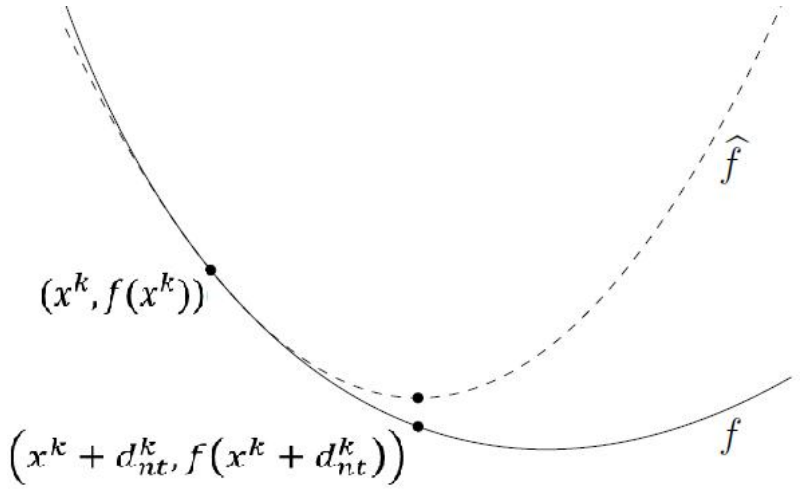
$$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k)$$

- Newton减少量 $\lambda(x^k) = \left(\nabla f(x^k)^{\mathsf{T}}\nabla^2 f(x^k)^{-1}\nabla f(x^k)\right)^{\frac{1}{2}}$
- Newton减少量是f在x^k处的二阶近似对$f(x)-p^*$做出的估计

f在x处二阶Taylor近似模型：$\hat{f}(x^k+v) = f(x^k) + \nabla f(x^k)^{\mathsf{T}} v + \frac{1}{2} v^{\mathsf{T}}\nabla^2 f(x^k) v$

$$\begin{aligned} f(x^k) - p^* &\approx f(x^k) - \min_v \hat{f}(x^k+v) \\ &= f(x^k) - \hat{f}(x^k + d_{nt}^k) \\ &= \frac{1}{2}\lambda(x^k)^2 \end{aligned}$$

牛顿方法停止准则：$\frac{1}{2}\lambda(x^k)^2 \le \varepsilon$



✓ 性质1：$\nabla f(x^k)^{\mathsf{T}} d_{nt}^k = -\lambda(x^k)^2$

✓ 性质2：$\lambda(x^k)^2 = (d_{nt}^k)^{\mathsf{T}}\nabla^2 f(x^k) d_{nt}^k$

Newton下降方法收敛性分析-以回溯直线搜索为例

$\min\ f(x)$

迭代求解最优性条件$\nabla f(x^*)=0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in dom\, f$，误差阈值$\varepsilon>0$，令$k=0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k);\ \lambda(x^k)^2 = \left(d_{nt}^k\right)^{\mathsf{T}}\nabla^2 f(x^k)\, d_{nt}^k$$

3. 停止准则：若$\frac{1}{2}\lambda(x^k)^2 \le \varepsilon$，退出
4. 回溯直线搜索：$0<\alpha<0.5,\ 0\le\beta\le 1, t^k=1$

While $f\left(x^k + t^k d_{nt}^k\right) > f(x^k) - \alpha t^k \lambda(x^k)^2$

$t^k := \beta t^k$

End

$f(x^k) + \alpha t^k \nabla f(x^k)^{\mathsf{T}} d_{nt}^k$

5. $x^{k+1} = x^k + t^k d_{nt}^k$，$k=k+1$，回2

假设：$\forall x, y \in S$，

- ✓ 存在m, M满足$mI \le \nabla^2 f(x) \le MI$
- ✓ 存在L满足$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \le L\|y-x\|_2$
  - ➢ 目标值与最优值间偏差的上界

$$f(x) - p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

  - ➢ 每次迭代目标改进值下界
    - ✓ 阻尼牛顿阶段：
    - ✓ 二次收敛阶段：
  - ➢ 算法收敛时，迭代次数的上界

$$f(x^K) - p^* \le \varepsilon \implies K \ge 6 + \frac{M^2L^2/m^5}{\alpha\beta\min\{1, 9(1-2\alpha)^2\}}\left(f(x^0) - p^*\right)$$

Newton下降方法收敛性分析-以回溯直线搜索为例

- 假设：函数f的Hessian矩阵以L为常数的Lipschitz 连续，即存在$L > 0$，使得

$$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2, \quad \forall x, y \in S$$

Spectral norm: https://en.wikipedia.org/wiki/Matrix_norm

- When $p = 2$, $\|\mathbf{A}\|_2$ is the spectral norm, the greatest singular value of $\mathbf{A}$, which is the square root of the greatest eigenvalue of $\mathbf{A}^*\mathbf{A}$, i.e., its spectral radius $\rho(\mathbf{A}^*\mathbf{A}) = \lambda_{max}(\mathbf{A}^*\mathbf{A})$,

$$\|\mathbf{A}\|_2 = \sigma_{max}(\mathbf{A}) = \sqrt{\lambda_{max}(\mathbf{A}^*\mathbf{A})} = \sqrt{\rho(\mathbf{A}^*\mathbf{A})}$$

where $\lambda_{max}(\mathbf{A}^*\mathbf{A}) = \sigma^2_{max}(\mathbf{A})$ is the maximal eigenvalue of $\mathbf{A}^*\mathbf{A}$, and $\sigma_{max}(\mathbf{A}) = \sqrt{\lambda(\mathbf{A}^*\mathbf{A})}$ the maximal singular value of $\mathbf{A}$. In Matlab this norm is implemented by the function `norm(A, 2)` or simply `norm(A)`.)

- ✓ L是和变量x无关的常数；
- ✓ L可解释为函数f 三阶导数的界，对于二次函数可以为0；
- ✓ L是函数f与其二次模型之间近似程度的一种度量，将对Newton方法的性能起关键作用；
- ✓ 若一个函数的二次模型变化缓慢（ L 值较小），Newton方法应该比较有效。

Newton下降方法收敛性分析-以回溯直线搜索为例

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k)$$

$$\lambda(x^k)=\left(\nabla f(x^k)^{\top}\nabla^2 f(x^k)^{-1}\nabla f(x^k)\right)^{\frac{1}{2}}$$

- 存在满足$0<\eta\le\frac{m^2}{L}$和$\gamma>0$的η和γ使得以下式子成立，

  - ✓ 阻尼牛顿阶段：如果$\left\|\nabla f(x^k)\right\|_2\ge\eta$，则$f(x^{k+1})-f(x^k)\le-\gamma$

  - ✓ 二次收敛阶段：如果$\left\|\nabla f(x^k)\right\|_2<\eta$，则回溯直线搜索产生$t^k=1$，并且

$$\frac{L}{2m^2}\left\|\nabla f(x^{k+1})\right\|_2\le\left(\frac{L}{2m^2}\left\|\nabla f(x^k)\right\|_2\right)^2$$

阻尼牛顿阶段

假设：$\forall x \in S$，存在m, M满足

$$mI \le \nabla^2 f(x) \le MI$$

4. 回溯直线搜索：$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$

$t^k := \beta t^k$

End

$f(x^k) + \alpha t^k \nabla f(x^k)^{\mathsf{T}} d_{nt}^k$

- 阻尼牛顿阶段：存在满足$0 < \eta \le \frac{m^2}{L}$，$\|\nabla f(x^k)\|_2 \ge \eta$，

$$f(x^{k+1}) - f(x^k) \le -\gamma$$

$$f(x^k + t d_{nt}^k) \le f(x^k) + t \nabla f(x^k)^{\mathsf{T}} d_{nt}^k + \frac{M \|d_{nt}^k\|_2^2}{2} t^2$$

$$\le f(x^k) - t\lambda(x^k)^2 + \frac{M}{2m} t^2 \lambda(x^k)^2$$

$$f(x^k + t_{min} d_{nt}^k) \le f(x^k) - \frac{m}{2M} \lambda(x^k)^2$$

$$t_{min} = \frac{m}{M}$$

$$\le f(x^k) - \alpha \frac{m}{M} \lambda(x^k)^2$$

$$\alpha < \frac{1}{2}$$

性质1：$\nabla f(x^k)^{\mathsf{T}} d_{nt}^k = -\lambda(x^k)^2$

性质2：$\lambda(x^k)^2 = (d_{nt}^k)^{\mathsf{T}} \nabla^2 f(x^k) d_{nt}^k \ge m \|d_{nt}^k\|_2^2$

阻尼牛顿阶段

假设：$\forall x \in S$，存在m, M满足

$$mI \le \nabla^2 f(x) \le MI$$

- 阻尼牛顿阶段：存在$0 < \eta \le \frac{m^2}{L}$，$\left\|\nabla f(x^k)\right\|_2 \ge \eta$，$f\left(x^k + t_{min} d_{nt}^k\right) \le f(x^k) - \alpha t_{min} \lambda(x^k)^2$，$t_{min} = \frac{m}{M}$

- 回溯直线搜索停止，$t \ge \beta t_{min} = \beta \frac{m}{M}$ 时，有

$t \ge min\left\{1, \frac{m}{M}\beta\right\}$

$$\begin{aligned} f\left(x^{k+1}\right) - f\left(x^k\right) &= f\left(x^k + t d_{nt}^k\right) - f\left(x^k\right) \\ &\le -\alpha t \lambda\left(x^k\right)^2 \\ &\le -\alpha\beta \frac{m}{M} \lambda\left(x^k\right)^2 \\ &\le -\alpha\beta \frac{m}{M^2} \left\|\nabla f\left(x^k\right)\right\|_2^2 \\ &\le -\alpha\beta\eta^2 \frac{m}{M^2} \quad \gamma \end{aligned}$$

$$\begin{aligned} &\lambda(x^k)^2 \\ &= \nabla f(x^k)^{\mathsf{T}} \nabla^2 f(x^k)^{-1} \nabla f(x^k) \\ &\ge \frac{1}{M} \left\|\nabla f(x^k)\right\|_2^2 \end{aligned}$$

阻尼牛顿阶段：如果$\left\|\nabla f\left(x^k\right)\right\|_2 \ge \eta$，则$f\left(x^{k+1}\right) - f\left(x^k\right) \le -\gamma$，即每次迭代目标函数至少减少$\gamma$，

阻尼牛顿阶段迭代次数小于等于$\frac{f(x^0) - p^*}{\gamma}$，这里$\gamma = \alpha\beta\eta^2 \frac{m}{M^2}$，$0 < \eta \le \frac{m^2}{L}$。

二次收敛阶段

二次收敛阶段：$\|\nabla f(x^k)\|_2 < \eta$，则$t^k = 1$，$\frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$

- 如果$\|\nabla f(x^k)\|_2 \le \eta \le 3(1-2\alpha)\frac{m^2}{L}$，则$t=1$满足回溯直线搜索停止条件，即

$$f(x^{k+1}) = f\left(x^k + d_{nt}^k\right) \le f(x^k) + \alpha \nabla f(x^k)^{\mathsf{T}} d_{nt}^k$$

证明：

$$\left\|\nabla^2 f\left(x^k + t d_{nt}^k\right) - \nabla^2 f(x^k)\right\|_2 \le tL\left\|d_{nt}^k\right\|_2$$

$$\left|\left(d_{nt}^k\right)^{\mathsf{T}}\left(\nabla^2 f\left(x^k + t d_{nt}^k\right) - \nabla^2 f(x^k)\right) d_{nt}^k\right| \le tL\left\|d_{nt}^k\right\|_2^3$$

$$\left|\tilde{f}''(t) - \tilde{f}''(0)\right| \le tL\left\|d_{nt}^k\right\|_2^3$$

$$\tilde{f}''(t) \le \tilde{f}''(0) + tL\left\|d_{nt}^k\right\|_2^3 \le \lambda(x^k)^2 + \frac{tL}{m^{3/2}}\lambda(x^k)^3$$

$$\tilde{f}'(t) \le \tilde{f}'(0) + t\lambda(x^k)^2 + \frac{t^2 L}{2m^{3/2}}\lambda(x^k)^3 = -\lambda(x^k)^2 + t\lambda(x^k)^2 + \frac{t^2 L}{2m^{3/2}}\lambda(x^k)^3$$

$$\tilde{f}(t) \le \tilde{f}(0) - t\lambda(x^k)^2 + \frac{1}{2}t^2\lambda(x^k)^2 + \frac{t^3 L}{6m^{3/2}}\lambda(x^k)^3$$

假设：$\forall x, y \in S$，存在m, M, L满足

- ✓ $mI \le \nabla^2 f(x) \le MI$；
- ✓ $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \le L\|y - x\|_2$

令$\tilde{f}(t) = f\left(x^k + t d_{nt}^k\right)$

- ✓ $\tilde{f}''(t) = (d_{nt}^k)^{\mathsf{T}}\nabla^2 f\left(x^k + t d_{nt}^k\right) d_{nt}^k$
- ✓ $\tilde{f}''(0) = \lambda(x^k)^2 \ge m\left\|d_{nt}^k\right\|_2^2$
- ✓ $\tilde{f}'(0) = -\lambda(x^k)^2$

二次收敛阶段

- 如果$\|\nabla f(x^k)\|_2 \le \eta \le 3(1-2\alpha)\frac{m^2}{L}$，则$t=1$满足回溯直线搜索停止条件，即

$$f(x^{k+1}) = f\left(x^k + d_{nt}^k\right) \le f(x^k) + \alpha \nabla f(x^k)^{\mathrm{T}} d_{nt}^k$$

证明：

$$\tilde{f}(t) \le \tilde{f}(0) - t\lambda(x^k)^2 + \frac{1}{2}t^2\lambda(x^k)^2 + \frac{t^3 L}{6m^{3/2}}\lambda(x^k)^3$$

$t=1$

$$f\left(x^k + d_{nt}^k\right) \le f(x^k) - \lambda(x^k)^2\left(\frac{1}{2} - \frac{L\lambda(x^k)}{6m^{3/2}}\right)$$

$$\le f(x^k) - \alpha\lambda(x^k)^2$$

$$= f(x^k) + \alpha\nabla f(x^k)^{\mathrm{T}} d_{nt}^k$$

$$f(x^{k+1}) = f\left(x^k + d_{nt}^k\right)$$

若$\|\nabla f(x^k)\|_2 \le \eta \le 3(1-2\alpha)\frac{m^2}{L}$，则

$$\lambda(x^k) = \left(\nabla f(x^k)^{\mathrm{T}} \nabla^2 f(x^k)^{-1} \nabla f(x^k)\right)^{1/2}$$

$$\le \frac{1}{m^{1/2}}\|\nabla f(x^k)\|_2$$

$$\le 3(1-2\alpha)\frac{m^{3/2}}{L}$$

二次收敛阶段：$\|\nabla f(x^k)\|_2 < \eta \le 3(1-2\alpha)\frac{m^2}{L}$，则回溯直线搜索产生$t^k = 1$

二次收敛阶段

二次收敛阶段：$\|\nabla f(x^k)\|_2 < \eta$，则回溯直线搜索产生$t^k = 1$，并且

$$\frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$$

假设：$\forall x, y \in S$，存在m, M, L满足

- ✓ $mI \le \nabla^2 f(x) \le MI$；
- ✓ $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \le L\|y - x\|_2$

- 二次收敛阶段：$\frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$

$$\nabla f(x^{k+1}) = \nabla f(x^k + d_{nt}^k) = \nabla f(x^k + d_{nt}^k) - \nabla f(x^k) - \nabla^2 f(x^k) d_{nt}^k$$

$$\|\nabla f(x^{k+1})\|_2 = \left\| \int_0^1 \left(\nabla^2 f(x^k + t d_{nt}^k) - \nabla^2 f(x^k)\right) d_{nt}^k dt \right\|_2$$

$$\le \int_0^1 Lt \|d_{nt}^k\|_2^2 dt = \frac{L}{2}\|d_{nt}^k\|_2^2$$

$$= \frac{L}{2}\left\|\nabla^2 f(x^k)^{-1}\nabla f(x^k)\right\|_2^2 \le \frac{L}{2m^2}\|\nabla f(x^k)\|_2^2$$

$$\frac{d\left(\nabla f(x^k + t d_{nt}^k)\right)}{dt} = \nabla^2 f(x^k + t d_{nt}^k) d_{nt}^k$$

二次收敛阶段：$\|\nabla f(x^k)\|_2 < \eta$，算法将选择单位步长，并且

$$\frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$$，这里$\eta = min\{1, 3(1-2\alpha)\}\frac{m^2}{L}$

二次收敛阶段

二次收敛阶段：$\|\nabla f(x^k)\|_2 < \eta$，则回溯直线搜索产生$t^k = 1$，并且

$$\frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$$

假设：$\forall x, y \in S$，存在m, M, L满足

- ✓ $mI \le \nabla^2 f(x) \le MI$；
- ✓ $\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \le L\|y - x\|_2$

- 二次收敛过程迭代次数k_2的上界

如果存在某个$\hat{k}$，使 $\left\|\nabla f\left(x^{\hat{k}}\right)\right\|_2 < \eta$，

$\forall K \ge \hat{k}$ → $\|\nabla f(x^K)\|_2 < \eta$ → 回溯直线搜索产生$t^K = 1$，并且 $\frac{L}{2m^2}\|\nabla f(x^{K+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^K)\|_2\right)^2$

二次收敛 $\left\|\nabla f\left(x^{\hat{k}}\right)\right\|_2 < \eta = min\{1, 3(1-2\alpha)\}\frac{m^2}{L}$

$$\frac{L}{2m^2}\|\nabla f(x^K)\|_2 \le \left(\frac{L}{2m^2}\left\|\nabla f\left(x^{\hat{k}}\right)\right\|_2\right)^{2^{K-\hat{k}}} \le \left(\frac{1}{2}\right)^{2^{K-\hat{k}}}$$

$$f(x^K) - p^* \le \frac{1}{2m}\|\nabla f(x^K)\|_2^2 \le \frac{2m^3}{L^2}\left(\frac{1}{2}\right)^{2^{K-\hat{k}+1}}$$

- 记$\epsilon_0 = \frac{2m^3}{L^2}$，$K_2 = K - \hat{k} + 1$，

$$f(x^K) - p^* \le \frac{1}{2m}\|\nabla f(x^K)\|_2^2 \le \epsilon \quad \Leftarrow \quad \frac{2m^3}{L^2}\left(\frac{1}{2}\right)^{2^{K-\hat{k}+1}} \le \epsilon \qquad K_2 \ge log_2(log_2(\epsilon_0/\epsilon))$$

Newton下降方法收敛性分析-以回溯直线搜索为例

- 存在满足$0 < \eta \leq \frac{m^2}{L}$和$\gamma > 0$的$\eta$和$\gamma$使得以下式子成立，
  - ✓ 阻尼牛顿阶段：如果$\left\|\nabla f(x^k)\right\|_2 \geq \eta$，则$f(x^{k+1}) - f(x^k) \leq -\gamma = -\alpha\beta\eta^2\frac{m}{M^2}$，即每次迭代目标函数至少减少$\gamma$，阻尼牛顿阶段迭代次数小于等于$\frac{f(x^0)-p^*}{\gamma}$。
  - ✓ 二次收敛阶段：如果$\left\|\nabla f(x^k)\right\|_2 < \eta$，则回溯直线搜索产生$t^k = 1$，有

$$\frac{L}{2m^2}\left\|\nabla f(x^{k+1})\right\|_2 \leq \left(\frac{L}{2m^2}\left\|\nabla f(x^k)\right\|_2\right)^2, \qquad \eta = min\{1,3(1-2\alpha)\}\frac{m^2}{L}$$

并且二次收敛阶段迭代次数不超过$log_2(log_2(\epsilon_0/\epsilon))$，这里$\epsilon_0 = \frac{2m^3}{L^2}$。

  - ✓ 回溯直线搜索的牛顿下降方法能够满足$f(x^K) - p^* \leq \epsilon$的总迭代次数$K$满足

$$K \geq \frac{f(x^0)-p^*}{\gamma} + log_2(log_2(\epsilon_0/\epsilon))$$

$$\approx \frac{f(x^0)-p^*}{\gamma} + 6$$

$$\approx \frac{M^2L^2/m^5}{\alpha\beta\min\{1,9(1-2\alpha)^2\}}(f(x^0) - p^*) + 6$$

随着误差阈值ϵ的减小极其缓慢地增长，一般视作常数5或6。实际上，二次迭代阶段的6次迭代可达到$\epsilon = 5 \cdot 10^{-20}\epsilon_0$。

回顾——牛顿方法

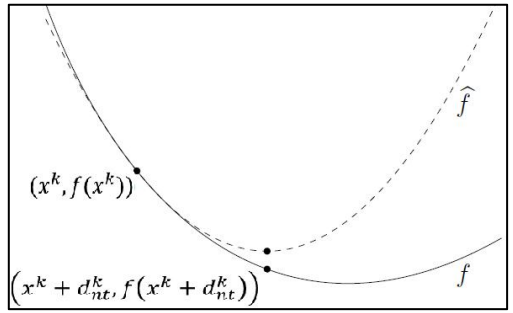
- 牛顿方向：$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k)$，这里，$\nabla^2 f(x^k) \epsilon S_{++}^n$，$\nabla f(x^k) \neq 0$
  - ✓ 二阶近似最优解：

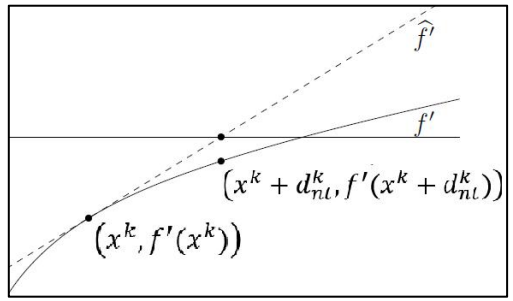
$$d_{nt}^k = \underset{v}{\operatorname{argmin}}\, \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^{\mathsf{T}} v + \frac{1}{2} v^{\mathsf{T}} \nabla^2 f(x^k) v$$

  - ✓ 线性化最优性条件的解：

$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0 \;\Rightarrow\; v = d_{nt}^k$$

- Newton减少量：$\lambda(x^k) = \left(\nabla f(x^k)^{\mathsf{T}} \nabla^2 f(x^k)^{-1} \nabla f(x^k)\right)^{\frac{1}{2}}$
  - ✓性质1：$\nabla f(x^k)^{\mathsf{T}} d_{nt}^k = -\lambda(x^k)^2$
  - ✓性质2：$\lambda(x^k)^2 = \left(d_{nt}^k\right)^{\mathsf{T}} \nabla^2 f(x^k) d_{nt}^k$





总结：牛顿下降回溯直线搜索算法

假设：$\forall x, y \in S$，

✓存在m, M满足$mI \le \nabla^2 f(x) \le MI$

✓存在L满足$\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \le L\|y - x\|_2$

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*) = 0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in dom\, f$，误差阈值$\varepsilon > 0$，令$k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k);\ \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k)\, d_{nt}^k$$

3. 停止准则：若 $\frac{1}{2}\lambda(x^k)^2 \le \varepsilon$，退出
4. 回溯直线搜索：$0 < \alpha < 0.5,\ 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d_{nt}^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{nt}^k$

$t^k := \beta t^k$

End

5. $x^{k+1} = x^k + t^k d_{nt}^k$，$k = k + 1$，回2

- 目标值与最优值间偏差的上界: $f(x) - p^* \le \frac{1}{2m}\|\nabla f(x^k)\|_2^2$
- 每次迭代目标改进值下界
  - 阻尼牛顿阶段（$0 < \eta \le \frac{m^2}{L}$，$\|\nabla f(x^k)\|_2 \ge \eta$）

    $f(x^{k+1}) - f(x^k) \le -\gamma$，迭代次数$\le \frac{f(x^0) - p^*}{\gamma}$，$\gamma = \alpha\beta\eta^2 \frac{m}{M^2}$
  - 二次收敛阶段（$\|\nabla f(x^k)\|_2 \le \eta \le 3(1-2\alpha)\frac{m^2}{L}$）
    - 回溯搜索$t^k = 1, \frac{L}{2m^2}\|\nabla f(x^{k+1})\|_2 \le \left(\frac{L}{2m^2}\|\nabla f(x^k)\|_2\right)^2$
    - 迭代次数 $\le log_2(log_2(\epsilon_0/\epsilon))$，$\epsilon_0 = \frac{2m^3}{L^2}$
- 算法收敛时，迭代次数的上界

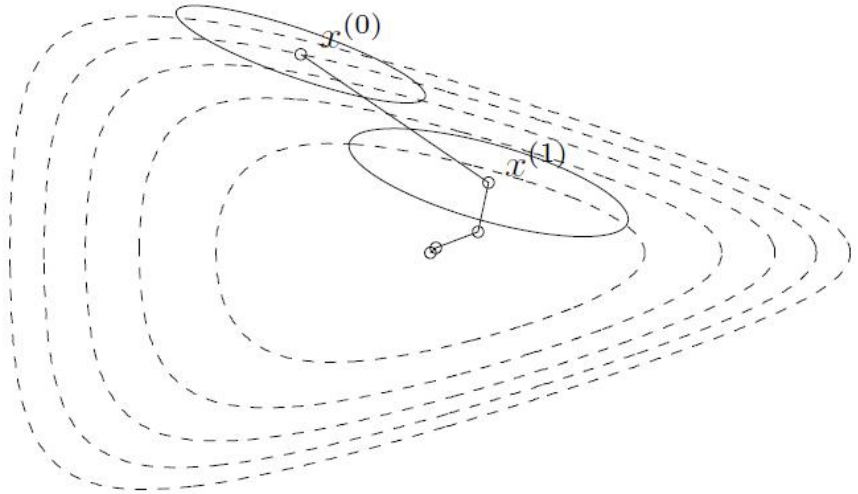
$f(x^K) - p^* \le \varepsilon \implies$

$$K \ge 6 + \frac{M^2 L^2 / m^5}{\alpha\beta \min\{1, 9(1-2\alpha)^2\}}(f(x^0) - p^*)$$

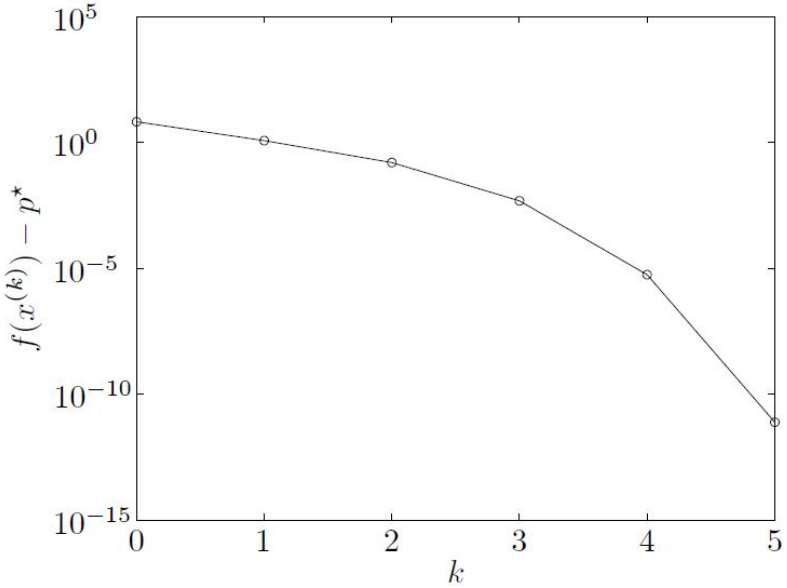
例1：两个变量的非二次规划问题

$$\min_x f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$

- 使用Newton下降方法，令回溯直线搜素时$\alpha = 0.1$，$\beta = 0.7$。



开始几次迭代过程



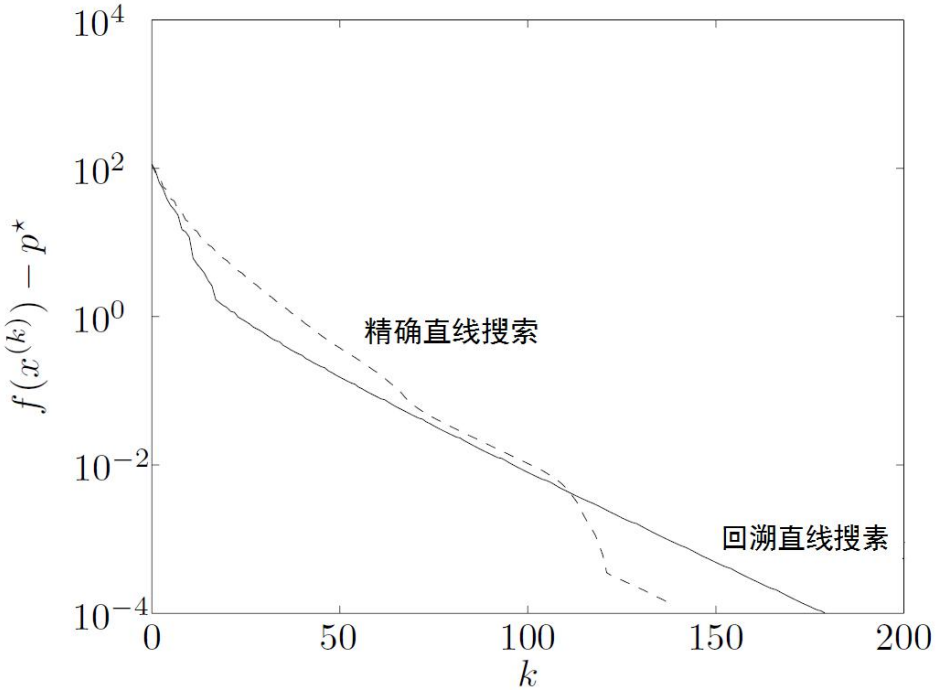
误差和迭代次数的关系

经过5次就收敛到了很高的精度

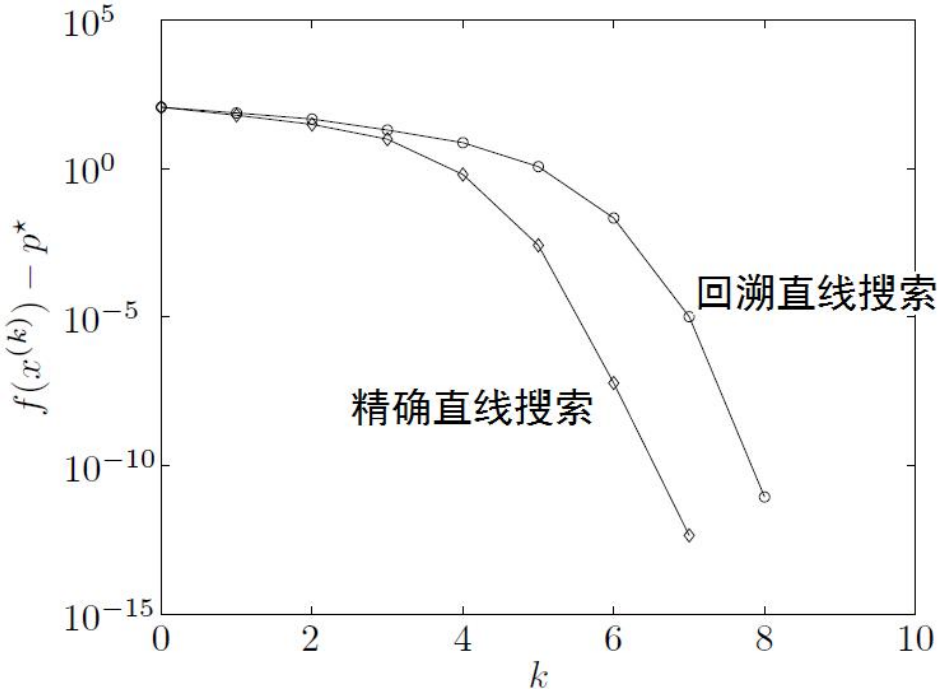
例2：高维变量的问题

$$f(x) = c^T x - \sum_{i=1}^{500} \log\left(b_i - a_i^T x\right)，\ x \in \mathbb{R}^{100}$$

- 分别使用精确直线搜索和回溯直线搜索$\alpha = 0.01$，$\beta = 0.5$



梯度下降方法迭代过程



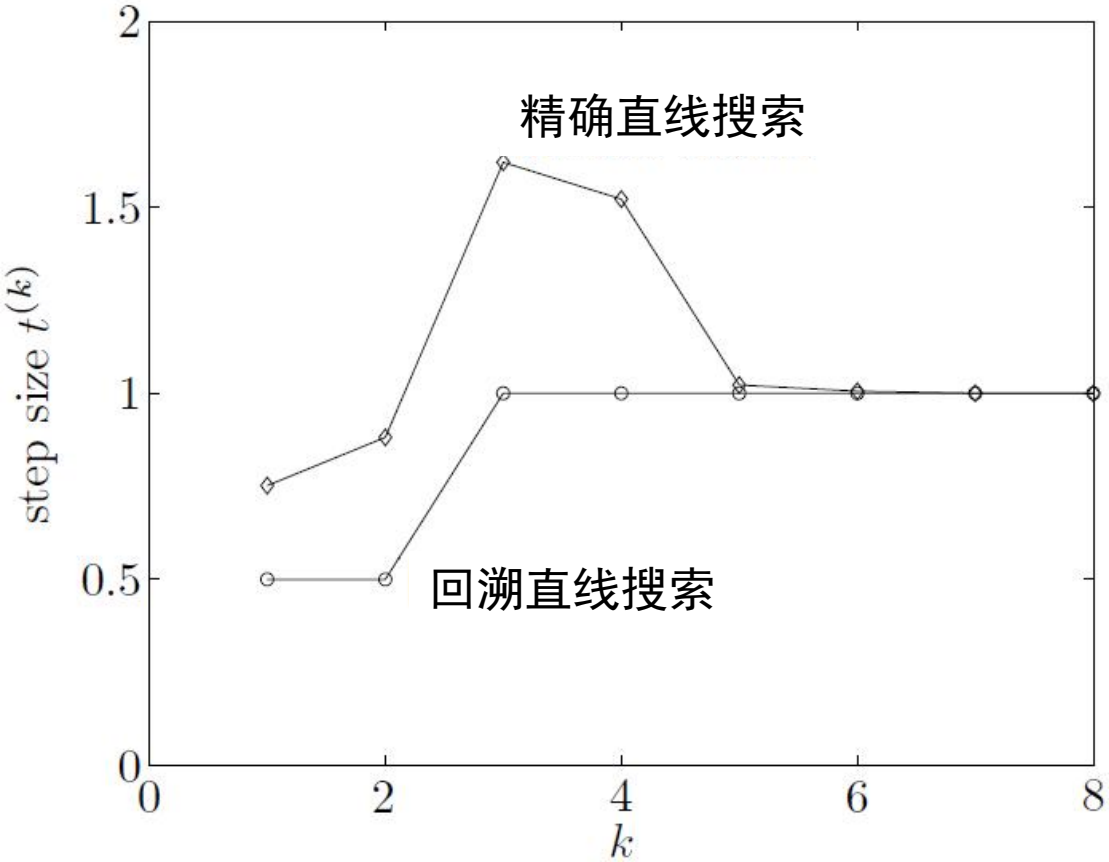
牛顿方法的迭代过程

- ✓ 在第三次迭代后二次收敛表现明显
- ✓ 精确直线搜索通常只对收敛速度有很小的改进

例2：高维变量的问题

$$f(x) = c^T x - \sum_{i=1}^{500} \log\left(b_i - a_i^T x\right)，\ x \in \mathbb{R}^{100}$$

- 分别使用精确直线搜索和回溯直线搜索$\alpha = 0.01$，$\beta = 0.5$



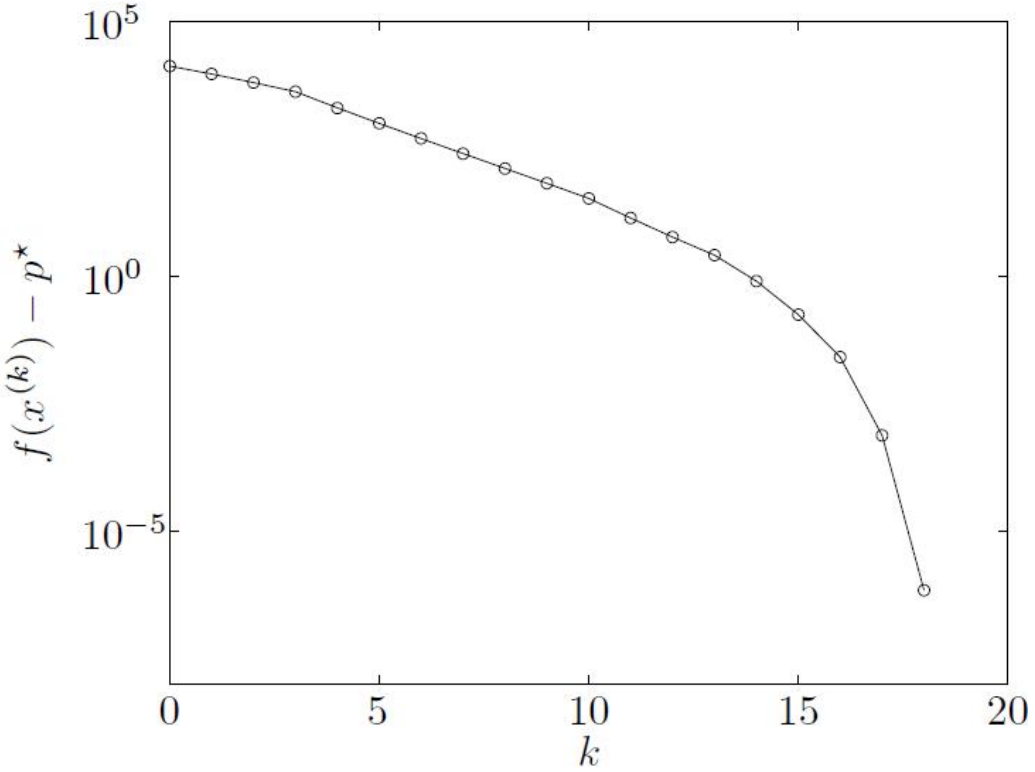
迭代步长随迭代次数变化

✓ 采用回溯直线搜索，在两次阻尼步长后，回溯直线搜索就采用完全步长，即$t^k = 1$.

例3：大规模问题

$$f(x) = -\sum_{i=1}^{10000} \log\left(1 - x_i^2\right) - \sum_{i=1}^{10000} \log\left(b_i - a_i^T x\right), \quad x \in \mathbb{R}^{10000}$$

- 牛顿下降方法：回溯直线搜索$\alpha = 0.01$，$\beta = 0.5$



误差与迭代次数的关系

- ✓ 最初的线性收敛阶段大约迭代了13次，随后的二次收敛过程经过4或5次迭代就获得了非常高的精度
- ✓ 即使对于大规模问题， Newton方法只需要18次迭代就获得了很高的精度

大作业-续上次大作业

对于$\mathbb{R}^2$空间非二次规划问题 $\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$，在上一个大作业负梯度方法求解基础上，采用牛顿方法进行求解，并分析回溯直线搜索采用不同的α, β值时，误差随迭代次数改变的情况。注：初始值相同。

作业

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*) = 0$

假设:

- ✓ 存在m, M满足$mI \leq \nabla^2 f(x) \leq MI\ (\forall x \in S)$
- ✓ 存在L满足$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$

证明：回溯直线搜索时牛顿方法的收敛性。

回顾：梯度下降方法及收敛性-精确直线搜索

精确直线搜索的梯度下降方法迭代次数的上界

$$K \geq \frac{\log((f(x^0)-p^*)/\varepsilon)}{|\log(1-\frac{m}{M})|}$$

分子: 初始次优性和最终次优性的比值的对数

分母: $|\log\left(1-\frac{m}{M}\right)| = -\log(1-\frac{m}{M}) \approx \frac{m}{M}$

- 初始次优性：$\log((f(x^0)-p^*)/\varepsilon)$，即$f(x^0)$和最优值$p^*$之间的缺口；
- 最终次优性：$f(x^K)-p^* \leq \varepsilon$，即$f(x^K)$和最优值$p^*$之间的缺口；
- 所需要迭代次数依赖于初始点的质量和对最终解的精度要求；
- 迭代次数的上界将随着$\frac{M}{m}$的增大而近似线性的增大。

回顾：梯度下降方法及收敛性-回溯直线搜索

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in dom\, f$，令$k=0$

2. 停止条件$\left\|\nabla f(x^k)\right\| \le \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 回溯直线搜索：$0<\alpha<0.5,\ 0<\beta<1, t^k=1$

While $f(x^k+t^k d^k) > f(x^k)+\alpha t^k \nabla f(x^k)^{\top} d^k$,

$t^k := \beta t^k$

End

5. $x^{k+1}=x^k+t^k d^k$，$k=k+1$，回2

✓ 收敛性分析

假设: 存在m, M满足$mI \le \nabla^2 f(x) \le MI\ (\forall x \in S)$

- 目标值与最优值间偏差的上界

$$f(x)-p^* \le \frac{1}{2m}||\nabla f(x)||_2^2$$

- 每次迭代目标改进值下界

$$f(x^{k+1}) \le f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\}||\nabla f(x^k)||_2^2$$

- 算法收敛时，迭代次数的上界

$$f(x^K)-p^* \le \varepsilon \implies K \ge \frac{\log\left((f(x^0)-p^*)/\varepsilon\right)}{\log(1/c)}$$

这里，$c=\left(1-\min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

仿射不变性

牛顿方向：$d_{nt}^{k} = -\nabla^2 f(x^k)^{-1}\nabla f(x^k)$，这里，$\nabla^2 f(x^k) \epsilon S_{++}^{n}$，$\nabla f(x^k) \neq 0$

✓ 牛顿步经对坐标的线性（或仿射）变换的独立性：$\forall T \in \mathbb{R}^{n\times n}$非奇异矩阵，令$x = Ty$，$\bar{f}(y) = f(Ty)$，有

$$\nabla \bar{f}(y) = T^{\mathrm{T}}\nabla f(x),\ \nabla^2 \bar{f}(y) = T^{\mathrm{T}}\nabla^2 f(x)T$$

$\bar{f}$在y处的牛顿步经：$d_{nt}^{y} = -\left(\nabla^2 \bar{f}(y)\right)^{-1}\nabla \bar{f}(y)$

$$= -\left(T^{\mathrm{T}}\nabla^2 f(x)T\right)^{-1}\left(T^{\mathrm{T}}\nabla f(x)\right)$$

$$= T^{-1}\left(-\left(\nabla^2 f(x)\right)^{-1}\nabla f(x)\right)$$

f在x处的牛顿步经d_{nt}^{x}

$$= T^{-1}d_{nt}^{x}$$

函数f和$\bar{f}$的牛顿步经由相同的线性变换相联系，并且$x + d_{nt}^{x} = T(y + d_{nt}^{y})$

回顾

- Newton减少量：

$$\lambda(x^k)=\left(\nabla f(x^k)^{\mathrm{T}}\nabla^2 f(x^k)^{-1}\nabla f(x^k)\right)^{\frac{1}{2}}$$

- ✓ 性质1：$\nabla f(x^k)^{\mathrm{T}} d_{nt}^k = -\lambda(x^k)^2$
- ✓ 性质2：$\lambda(x^k)^2=\left(d_{nt}^k\right)^{\mathrm{T}}\nabla^2 f(x^k) d_{nt}^k$

回顾：Newton下降方法收敛性分析-回溯直线搜索

$$\min\ f(x)$$

迭代求解最优性条件$\nabla f(x^*)=0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in dom\, f$，误差阈值$\varepsilon>0$，令$k=0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k);\ \lambda(x^k)^2 = (d_{nt}^k)^{\mathsf{T}}\nabla^2 f(x^k)\, d_{nt}^k$$

3. 停止准则：若$\frac{1}{2}\lambda(x^k)^2 \le \varepsilon$，退出
4. 回溯直线搜索：$0<\alpha<0.5,\ 0<\beta<1,\ t^k=1$

While $f(x^k+t^k d_{nt}^k) > f(x^k)-\alpha t^k\lambda(x^k)^2$

$t^k := \beta t^k$

End

$f(x^k)+\alpha t^k \nabla f(x^k)^{\mathsf{T}} d_{nt}^k$

5. $x^{k+1}=x^k+t^k d_{nt}^k$，$k=k+1$，回2

假设：$\forall x, y \in S$，

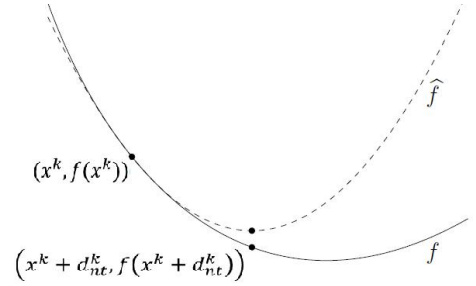
- ✓ 存在m, M满足$mI \le \nabla^2 f(x) \le MI$
- ✓ 存在L满足$\|\nabla^2 f(y)-\nabla^2 f(x)\|_F \le L\|y-x\|_2$
- ➢ 目标值与最优值间偏差的上界

$$f(x)-p^* \le \frac{1}{2m}\|\nabla f(x)\|_2^2$$

- ➢ 每次迭代目标改进值下界
- ✓ 阻尼牛顿阶段：$0<\eta\le\frac{m^2}{L},\ \|\nabla f(x^k)\|_2 \ge \eta$
- ✓ 二次收敛阶段：$\|\nabla f(x^k)\|_2 \le \eta \le 3(1-2\alpha)\frac{m^2}{L}$
- ➢ 算法收敛时，迭代次数的上界

$$f(x^K)-p^* \le \varepsilon \implies K \ge 6+\frac{M^2L^2/m^5}{\alpha\beta\min\{1,9(1-2\alpha)^2\}}(f(x^0)-p^*)$$

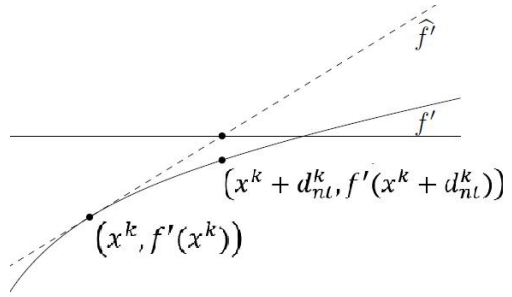
回顾——牛顿方法



- 牛顿方向：$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$，这里，$\nabla^2 f(x^k) \epsilon S_{++}^n$，$\nabla f(x^k) \neq 0$

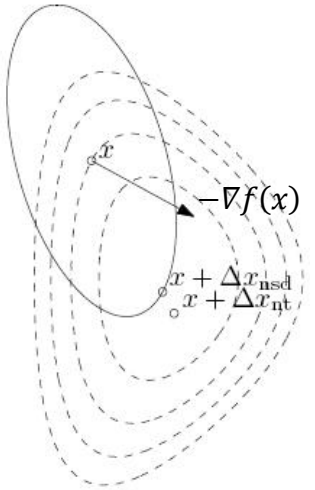
  - ✓ 二阶近似最优解：

$$d_{nt}^k = \underset{v}{\operatorname{argmin}}\, \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^\top v + \frac{1}{2} v^\top \nabla^2 f(x^k) v$$



  - ✓ 线性化最优性条件的解：

$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0 \;\Rightarrow\; v = d_{nt}^k$$



  - ✓ Hessian范数下的最速下降方向：

$$d_{nt}^k = d_{sd}^k = \left\|\nabla f(x^k)\right\|_* \times d_{nsd}^k$$

$$= \left\|\nabla f(x^k)\right\|_* \times \arg\min_d \{\nabla f(x^k)^\top d : \|d\|_{\nabla^2 f(x^k)} = 1\}$$

回顾：阻尼牛顿阶段

假设：$\forall x \in S$，存在m, M满足

$$mI \le \nabla^2 f(x) \le MI$$

4. 回溯直线搜索：$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$

$t^k := \beta t^k$

End

$f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{nt}^k$

- 阻尼牛顿阶段：存在满足$0 < \eta \le \frac{m^2}{L}$，$\|\nabla f(x^k)\|_2 \ge \eta$，

$$f(x^k + t_{min} d_{nt}^k) \le f(x^k) - \alpha t_{min} \lambda(x^k)^2，这里，t_{min} = \frac{m}{M}$$

➢ 回溯直线搜索停止，$t \ge \beta t_{min} = \beta \frac{m}{M}$时，有

$$f(x^k + t d_{nt}^k) - f(x^k) \le -\alpha t \lambda(x^k)^2 \le -\alpha\beta \frac{m}{M} \lambda(x^k)^2$$

$$\le -\alpha\beta \frac{m}{M^2} \|\nabla f(x^k)\|_2^2$$

$$\le -\alpha\beta\eta^2 \frac{m}{M^2} \quad \gamma$$

$$\lambda(x^k)^2 = \nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \ge \frac{1}{M} \|\nabla f(x^k)\|_2^2$$

阻尼牛顿阶段：如果$\|\nabla f(x^k)\|_2 \ge \eta$，则$f(x^{k+1}) - f(x^k) \le -\gamma$，即每次迭代目标函数至少减少$\gamma$，

阻尼牛顿阶段迭代次数小于等于$\frac{f(x^0) - p^*}{\gamma}$，这里$\gamma = \alpha\beta\eta^2 \frac{m}{M^2}$，$0 < \eta \le \frac{m^2}{L}$。

回顾

- 假设：函数f的Hessian矩阵以L为常数的Lipschitz 连续，即存在$L > 0$，使得

$$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2, \quad \forall x, y \in S$$

Spectral norm: https://en.wikipedia.org/wiki/Matrix_norm

- When $p = 2$, $\|\mathbf{A}\|_2$ is the spectral norm, the greatest singular value of $\mathbf{A}$, which is the square root of the greatest eigenvalue of $\mathbf{A}^*\mathbf{A}$, i.e., its spectral radius $\rho(\mathbf{A}^*\mathbf{A}) = \lambda_{max}(\mathbf{A}^*\mathbf{A})$,

$$\|\mathbf{A}\|_2 = \sigma_{max}(\mathbf{A}) = \sqrt{\lambda_{max}(\mathbf{A}^*\mathbf{A})} = \sqrt{\rho(\mathbf{A}^*\mathbf{A})}$$

where $\lambda_{max}(\mathbf{A}^*\mathbf{A}) = \sigma^2_{max}(\mathbf{A})$ is the maximal eigenvalue of $\mathbf{A}^*\mathbf{A}$, and $\sigma_{max}(\mathbf{A}) = \sqrt{\lambda(\mathbf{A}^*\mathbf{A})}$ the maximal singular value of $\mathbf{A}$. In Matlab this norm is implemented by the function `norm(A, 2)` or simply `norm(A)`.)

- ✓ L是和变量x无关的常数；
- ✓ L可解释为函数f 三阶导数的界，对于二次函数可以为0；
- ✓ L是函数f与其二次模型之间近似程度的一种度量，将对Newton方法的性能起关键作用；
- ✓ 若一个函数的二次模型变化缓慢（ L 值较小），Newton方法应该比较有效。